

Otimização Estocástica 2/4

Decomposição, Dualidade e Aversão ao Risco

Bernardo Freitas Paulo da Costa (FGV EMap)

Sobrapo School 2025
14 de Novembro de 2025



Minha História

1. 2003-2004: Início da graduação, Engenharia de Eletrônica e Computação (UFRJ);
2. 2005-2008: Duplo diploma com Polytechnique Paris / Matemática Aplicada (UFRJ);
3. 2009-2012: Doutorado em Matemática (Paris Sud $\Rightarrow$ Paris Saclay);
4. 2012-2013: Pós-doutorado (Purdue, EUA);
5. 2013-2022: Professor Adjunto (UFRJ, Instituto de Matemática);
 - 2019: Professor Visitante (ISyE – Georgia Tech, EUA);
6. 2023-presente: Professor Associado (FGV EMap).

Plano

1. Função de Retorno: Propriedades
2. Função Valor e Decomposição em cenários
3. Dualidade e Algoritmos de planos cortantes para 2 estágios
4. Aversão ao Risco

O Jornaleiro

- Decisão no primeiro estágio: comprar x jornais;
- Incerteza: demanda ξ de jornais;
- Decisão no segundo estágio: vender y jornais, devolver z ;

O Jornaleiro

- Decisão no primeiro estágio: comprar x jornais;
- Incerteza: demanda ξ de jornais;
- Decisão no segundo estágio: vender y jornais, devolver z ;

Primeiro estágio

$$\begin{array}{ll} \max_x & -cx + \mathcal{R}_1^F(x) \\ \text{s.a.} & 0 \leq x \leq \bar{x} \end{array}$$

$$\mathcal{R}_1^F(x) = \mathbb{E}_{\xi} \left[\mathcal{R}_1^F(x, \xi) \right]$$

O Jornaleiro

- Decisão no primeiro estágio: comprar x jornais;
- Incerteza: demanda ξ de jornais;
- Decisão no segundo estágio: vender y jornais, devolver z ;

Primeiro estágio


$$\begin{array}{ll} \max_x & -cx + \mathcal{R}_1^F(x) \\ \text{s.a.} & 0 \leq x \leq \bar{x} \end{array}$$

$$\mathcal{R}_1^F(x) = \mathbb{E}_{\xi} \left[\mathcal{R}_1^F(x, \xi) \right]$$


Segundo estágio

$$\begin{array}{ll} \mathcal{R}_1^F(x, \xi) = \max_{y,z} & qy + rz \\ \text{s.a.} & 0 \leq y \leq \xi \\ & 0 \leq z \\ & y + z \leq x \end{array}$$


Função de Retorno



Função de Retorno



Função de Retorno



Retorno esperado e Função valor

- Função de Retorno esperado:

$$\mathcal{R}_1^F(x) = \mathbb{E}_{\xi} \left[\mathcal{R}_1^F(x, \xi) \right]$$

Retorno esperado e Função valor

- Função de Retorno esperado:

$$\mathcal{R}_1^F(x) = \mathbb{E}_{\xi} \left[\mathcal{R}_1^F(x, \xi) \right]$$

- Função Valor: nome genérico
 - tanto para retorno como custo (max ou min),
 - pode incluir aversão ao risco.


Retorno esperado e Função valor

- Função de Retorno esperado:

$$\mathcal{R}_1^F(x) = \mathbb{E}_{\xi} \left[\mathcal{R}_1^F(x, \xi) \right]$$


- Função Valor: nome genérico
 - tanto para retorno como custo (max ou min),
 - pode incluir aversão ao risco.
 - Muitas vezes denotada por $V(x)$,
 - $\Rightarrow V_t(x)$ com mais estágios.

Função Valor do Jornaleiro




Função Valor do Jornaleiro

3 cenários



Função Valor do Jornaleiro


201 cenários



O problema do primeiro estágio

3 cenários


Função objetivo do 1º estágio
 $-cx + V(x)$



O problema do primeiro estágio


201 cenários

Função objetivo do 1º estágio
 $-cx + V(x)$




O problema do primeiro estágio

SAA 3 cenários




O problema do primeiro estágio

SAA 3 cenários




O problema do primeiro estágio

SAA 3 cenários




O problema do primeiro estágio

SAA 3 cenários




O problema do primeiro estágio

SAA 10 cenários




O problema do primeiro estágio

SAA 10 cenários




O problema do primeiro estágio

SAA 10 cenários



O problema do primeiro estágio

SAA 10 cenários



Problema de 2 estágios geral

$$\begin{array}{ll}\max_x & c^\top x + V(x) \\ \text{s.a.} & Ax \leq b\end{array}$$

- x : decisões do primeiro estágio;
- c, A, b : parâmetros do primeiro estágio;

Problema de 2 estágios geral

$$\begin{array}{ll} \max_x & c^\top x + V(x) \\ \text{s.a.} & Ax \leq b \end{array}$$

$$V(x) = \mathbb{E}_{\xi} \left[\mathcal{R}_1^F(x, \xi) \right]$$

- x : decisões do primeiro estágio;
- c, A, b : parâmetros do primeiro estágio;
- ξ : vetor de parâmetros estocásticos

Problema de 2 estágios geral

$$\begin{aligned} \max_x \quad & c^\top x + V(x) \\ \text{s.a.} \quad & Ax \leq b \end{aligned}$$

$$V(x) = \mathbb{E}_\xi \left[\mathcal{R}_1^F(x, \xi) \right]$$

$$\begin{aligned} \mathcal{R}_1^F(x, \xi) = \max_y \quad & d^\top y \\ \text{s.a.} \quad & Tx + Wy \leq h \end{aligned}$$

- x : decisões do primeiro estágio;
- c, A, b : parâmetros do primeiro estágio;
- ξ : vetor de parâmetros estocásticos
 - pode afetar d, T, W e h ;
- y : decisões do segundo estágio.

Função de Retorno e convexidade

Teorema

Seja $\mathcal{R}_1^F(x, \xi) = \max_y d^\top y$ a função de retorno do segundo estágio de um problema de programação linear.
s.a. $Tx + Wy \leq h$

Para ξ fixo, a função de retorno $\mathcal{R}_1^F(x, \xi)$ é uma função *côncava* de x .

Função de Retorno e convexidade

Teorema

Seja $\mathcal{R}_1^F(x, \xi) = \max_y d^\top y$ a função de retorno do segundo estágio de um problema de programação linear.
s.a. $Tx + Wy \leq h$

Para ξ fixo, a função de retorno $\mathcal{R}_1^F(x, \xi)$ é uma função **côncava** de x .

Demonstração.

Sejam $x_0, x_1 \in \mathbb{R}^n$ e sejam y_0 e y_1 soluções ótimas para $\mathcal{R}_1^F(x_0, \xi)$ e $\mathcal{R}_1^F(x_1, \xi)$.
Seja $\lambda \in [0, 1]$ e defina $x_\lambda = \lambda x_1 + (1 - \lambda)x_0$, e observe que $y_\lambda = \lambda y_1 + (1 - \lambda)y_0$ é viável para $\mathcal{R}_1^F(x_\lambda, \xi)$ (basta somar as restrições ponderadas por λ e $1 - \lambda$). Então

$$\begin{aligned}\mathcal{R}_1^F(x_\lambda, \xi) &\geq d^\top (\lambda y_1 + (1 - \lambda)y_0) = \lambda d^\top y_1 + (1 - \lambda)d^\top y_0 \\ &= \lambda \mathcal{R}_1^F(x_1, \xi) + (1 - \lambda)\mathcal{R}_1^F(x_0, \xi).\end{aligned}$$



Função de Retorno e convexidade

Teorema

Seja $\mathcal{R}_1^F(x, \xi) = \max_y d^\top y$ a função de retorno do segundo estágio de um problema de programação linear.
s.a. $Tx + Wy \leq h$

Para ξ fixo, a função de retorno $\mathcal{R}_1^F(x, \xi)$ é uma função *côncava* de x .

Corolário

A função valor

$$V(x) = \mathbb{E}_{\xi} \left[\mathcal{R}_1^F(x, \xi) \right]$$

é côncava.

Algumas considerações computacionais

- Construir um `JuMP.Model` leva tempo;
- Resolver o modelo pode ser rápido ou demorado;
- Re-resolver um problema de otimização pode ser *muito mais rápido*:
 - dispensando enviar o modelo inteiro ao solver;
 - aproveitando uma solução inicial (*warm-start*);

Algumas considerações computacionais

- Construir um `JuMP.Model` leva tempo;
- Resolver o modelo pode ser rápido ou demorado;
- Re-resolver um problema de otimização pode ser *muito mais rápido* :
 - dispensando enviar o modelo inteiro ao solver;
 - aproveitando uma solução inicial (*warm-start*);

Cálculo de $V(x) = \mathbb{E}_{\xi}[\mathcal{R}_1^F(x, \xi)]$: variando ξ

```
julia> @time V(155, distr_demanda_unif)
0.247674 seconds (525.21 k allocations: 12.553 MiB, 2.73% gc time)
```

Algumas considerações computacionais

- Construir um `JuMP.Model` leva tempo;
- Resolver o modelo pode ser rápido ou demorado;
- Re-resolver um problema de otimização pode ser *muito mais rápido* :
 - dispensando enviar o modelo inteiro ao solver;
 - aproveitando uma solução inicial (*warm-start*);

Cálculo de $V(x) = \mathbb{E}_{\xi}[\mathcal{R}_1^F(x, \xi)]$: **variando ξ**

```
julia> @time V(155, distr_demanda_unif)
0.247674 seconds (525.21 k allocations: 12.553 MiB, 2.73% gc time)
```

```
julia> @time funcao_valor(155, distr_demanda_unif)
0.007220 seconds (5.25 k allocations: 134.891 KiB)
```

Algumas considerações computacionais

- Construir um `JuMP.Model` leva tempo;
- Resolver o modelo pode ser rápido ou demorado;
- Re-resolver um problema de otimização pode ser *muito mais rápido* :
 - dispensando enviar o modelo inteiro ao solver;
 - aproveitando uma solução inicial (*warm-start*);

Cálculo de $x \mapsto \mathcal{R}_1^F(x, \xi)$: **variando x**

```
julia> @time receita_futura_lenta(100:300, 127);  
0.238208 seconds (525.22 k allocations: 12.555 MiB, 2.68% gc time)
```

Algumas considerações computacionais

- Construir um `JuMP.Model` leva tempo;
- Resolver o modelo pode ser rápido ou demorado;
- Re-resolver um problema de otimização pode ser *muito mais rápido* :
 - dispensando enviar o modelo inteiro ao solver;
 - aproveitando uma solução inicial (*warm-start*);

Cálculo de $x \mapsto \mathcal{R}_1^F(x, \xi)$: **variando x**

```
julia> @time receita_futura_lenta(100:300, 127);  
0.238208 seconds (525.22 k allocations: 12.555 MiB, 2.68% gc time)
```

```
julia> @time receita_futura(100:300, 127);  
0.007887 seconds (5.46 k allocations: 145.547 KiB)
```

Decomposição em cenários

Fixar x , variar ξ

- Constrói o modelo uma vez;
- Re-resolve para cada ξ ;
- Permite calcular $V(x)$ eficientemente.

Decomposição em cenários

Fixar x , variar ξ

- Constrói o modelo uma vez;
- Re-resolve para cada ξ ;
- Permite calcular $V(x)$ eficientemente.


Desacopla os cenários do segundo estágio
ao *fixar a decisão do primeiro estágio*.

Decomposição em cenários

Fixar x , variar ξ

- Constrói o modelo uma vez;
- Re-resolve para cada ξ ;
- Permite calcular $V(x)$ eficientemente.

Desacopla os cenários do segundo estágio ao *fixar a decisão do primeiro estágio*.



Plano

1. Função de Retorno: Propriedades
2. Função Valor e Decomposição em cenários
3. *Dualidade e Algoritmos de planos cortantes para 2 estágios*
4. Aversão ao Risco

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$
- Lagrangiano: $\mathcal{L}(x, \mu) = c^\top x + \mu^\top (Ax - b)$

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$
- Lagrangiano: $\mathcal{L}(x, \mu) = c^\top x + \mu^\top (Ax - b)$
 - Penalidade: se viola a restrição, piora a função objetivo;

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$
- Lagrangiano: $\mathcal{L}(x, \mu) = c^\top x + \mu^\top (Ax - b)$
 - Penalidade: se viola a restrição, piora a função objetivo;
 - Se $Ax \geq b$, então $\mu^\top (Ax - b) \leq 0$;

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$
- Lagrangiano: $\mathcal{L}(x, \mu) = c^\top x + \mu^\top (Ax - b)$
 - Penalidade: se viola a restrição, piora a função objetivo;
 - Se $Ax \geq b$, então $\mu^\top (Ax - b) \leq 0$;
 - Então $\mu \leq 0$.

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$
- Lagrangiano: $\mathcal{L}(x, \mu) = c^\top x + \mu^\top (Ax - b)$
 - Penalidade: se viola a restrição, piora a função objetivo;
 - Se $Ax \geq b$, então $\mu^\top (Ax - b) \leq 0$;
 - Então $\mu \leq 0$.
- Função dual: $g(\mu) = \max_x \mathcal{L}(x, \mu)$

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$
- Lagrangiano: $\mathcal{L}(x, \mu) = c^\top x + \mu^\top (Ax - b) = (c + A^\top \mu)^\top x - \mu^\top b$
 - Penalidade: se viola a restrição, piora a função objetivo;
 - Se $Ax \geq b$, então $\mu^\top (Ax - b) \leq 0$;
 - Então $\mu \leq 0$.
- Função dual: $g(\mu) = \max_x \mathcal{L}(x, \mu) = \begin{cases} -b^\top \mu & \text{se } c + A^\top \mu = 0 \\ +\infty & \text{caso contrário} \end{cases}$

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$
- Lagrangiano: $\mathcal{L}(x, \mu) = c^\top x + \mu^\top (Ax - b) = (c + A^\top \mu)^\top x - \mu^\top b$
 - Penalidade: se viola a restrição, piora a função objetivo;
 - Se $Ax \geq b$, então $\mu^\top (Ax - b) \leq 0$;
 - Então $\mu \leq 0$.
- Função dual: $g(\mu) = \max_x \mathcal{L}(x, \mu) = \begin{cases} -b^\top \mu & \text{se } c + A^\top \mu = 0 \\ +\infty & \text{caso contrário} \end{cases}$
- Problema dual: $\min_{\mu \leq 0} g(\mu) \equiv \min_{\mu \leq 0} \{-b^\top \mu : c + A^\top \mu = 0\}.$

Dualidade e Lagrangiano

- Problema primal: $\max_x \{c^\top x : Ax \leq b\}$
- Lagrangiano: $\mathcal{L}(x, \mu) = c^\top x + \mu^\top (Ax - b) = (c + A^\top \mu)^\top x - \mu^\top b$
 - Penalidade: se viola a restrição, piora a função objetivo;
 - Se $Ax \geq b$, então $\mu^\top (Ax - b) \leq 0$;
 - Então $\mu \leq 0$.
- Função dual: $g(\mu) = \max_x \mathcal{L}(x, \mu) = \begin{cases} -b^\top \mu & \text{se } c + A^\top \mu = 0 \\ +\infty & \text{caso contrário} \end{cases}$
- Problema dual: $\min_{\mu \leq 0} g(\mu) \equiv \min_{\mu \leq 0} \{-b^\top \mu : c + A^\top \mu = 0\}$.

Referências de convenção de sinais em JuMP:

- https://jump.dev/JuMP.jl/stable/manual/constraints/#constraint_duality
- <https://jump.dev/JuMP.jl/stable/moi/background/duality/>

Dualidade Fraca e Dualidade Forte

- *Dualidade fraca*: para qualquer $\mu \leq 0$ e qualquer x viável ($Ax \leq b$),

$$f(x) = c^\top x \leq \underbrace{c^\top x + \mu^\top (Ax - b)}_{\mathcal{L}(x, \mu)} \leq -b^\top \mu = g(\mu).$$

Dualidade Fraca e Dualidade Forte

- *Dualidade fraca*: para qualquer $\mu \leq 0$ e qualquer x viável ($Ax \leq b$),

$$f(x) = c^\top x \leq \underbrace{c^\top x + \mu^\top (Ax - b)}_{\mathcal{L}(x, \mu)} \leq -b^\top \mu = g(\mu).$$

- Logo $\max_{Ax \leq b} c^\top x \leq \min_{\mu \leq 0} g(\mu)$.

Dualidade Fraca e Dualidade Forte

- *Dualidade fraca*: para qualquer $\mu \leq 0$ e qualquer x viável ($Ax \leq b$),

$$f(x) = c^\top x \leq \underbrace{c^\top x + \mu^\top (Ax - b)}_{\mathcal{L}(x, \mu)} \leq -b^\top \mu = g(\mu).$$

‣ Logo $\max_{Ax \leq b} c^\top x \leq \min_{\mu \leq 0} g(\mu)$.

- *Dualidade forte*: quando vale a igualdade, em particular, se existem

1. $\bar{x}$ viável para o primal ($A\bar{x} \leq b$),
2. $\bar{\mu}$ viável para o dual ($\bar{\mu} \leq 0$), e
3. $f(\bar{x}) = g(\bar{\mu})$.

Dualidade Fraca e Dualidade Forte

- *Dualidade fraca*: para qualquer $\mu \leq 0$ e qualquer x viável ($Ax \leq b$),

$$f(x) = c^\top x \leq \underbrace{c^\top x + \mu^\top (Ax - b)}_{\mathcal{L}(x, \mu)} \leq -b^\top \mu = g(\mu).$$

‣ Logo $\max_{Ax \leq b} c^\top x \leq \min_{\mu \leq 0} g(\mu)$.

- *Dualidade forte*: quando vale a igualdade, em particular, se existem

1. $\bar{x}$ viável para o primal ($A\bar{x} \leq b$),
2. $\bar{\mu}$ viável para o dual ($\bar{\mu} \leq 0$), e
3. $f(\bar{x}) = g(\bar{\mu})$.

$\Rightarrow \bar{x}$ e $\bar{\mu}$ são ótimos para primal e dual, respectivamente.

Dualidade no Segundo Estágio

- Problema do 2º estágio: $\mathcal{R}_1^F(\mathbf{x}, \xi) = \max_y d^\top y$
s.a. $T\mathbf{x} + Wy \leq h \quad [\mu]$

Dualidade no Segundo Estágio

- Problema do 2º estágio: $\mathcal{R}_1^F(\mathbf{x}, \xi) = \max_y d^\top y$
s.a. $T\mathbf{x} + Wy \leq h \quad [\mu]$
- Lagrangiano: $\mathcal{L}(y, \mu) = d^\top y + \mu^\top (T\mathbf{x} + Wy - h)$.

Dualidade no Segundo Estágio

- Problema do 2º estágio: $\mathcal{R}_1^F(\mathbf{x}, \xi) = \max_y d^\top y$
s.a. $T\mathbf{x} + Wy \leq h \quad [\mu]$
- Lagrangiano: $\mathcal{L}(\mathbf{x}, \xi; y, \mu) = d^\top y + \mu^\top (T\mathbf{x} + Wy - h).$

Dualidade no Segundo Estágio

- Problema do 2º estágio: $\mathcal{R}_1^F(\mathbf{x}, \xi) = \max_y d^\top y$
s.a. $T\mathbf{x} + Wy \leq h \quad [\mu]$
- Lagrangiano: $\mathcal{L}(\mathbf{x}, \xi; y, \mu) = d^\top y + \mu^\top (T\mathbf{x} + Wy - h)$.

Por *dualidade fraca*, para qualquer $\mu \leq 0$,

$$\begin{aligned}\mathcal{R}_1^F(\mathbf{x}, \xi) &\leq \max_y \mathcal{L}(\mathbf{x}, \xi; y, \mu) \\ &= \mu^\top (T\mathbf{x} - h) + \max_y \{(d + W^\top \mu)^\top y\} \\ &= \begin{cases} \mu^\top (T\mathbf{x} - h) & \text{se } d + W^\top \mu = 0 \\ +\infty & \text{caso contrário} \end{cases}\end{aligned}$$

Dualidade via variável auxiliar

- Não queremos calcular multiplicadores para todas as restrições;

- **Variável “cópia”** $\hat{x} = x$ permite escrever $\mathcal{R}_1^F(x, \xi) = \begin{array}{ll} \max_{\hat{x}, y} & d^\top y \\ \text{s.a.} & T\hat{x} + Wy \leq h \\ & \hat{x} = x \end{array} \quad [\pi]$

Dualidade via variável auxiliar

- Não queremos calcular multiplicadores para todas as restrições;

- **Variável “cópia”** $\hat{x} = x$ permite escrever $\mathcal{R}_1^F(x, \xi) = \max_{\hat{x}, y} d^\top y$
s.a. $T\hat{x} + Wy \leq h$
 $\hat{x} = x$ $[\pi]$

- Lagrangiano “parcial”: $\mathcal{L}(x, \xi; \hat{x}, y, \pi) = d^\top y + \pi^\top (x - \hat{x})$;

- Por **dualidade fraca**:

$$\mathcal{R}_1^F(x, \xi) \leq \bar{\pi}^\top x + \max_{\hat{x}, y} \{d^\top y - \bar{\pi}^\top \hat{x} : T\hat{x} + Wy \leq h\}.$$

Dualidade via variável auxiliar

- Não queremos calcular multiplicadores para todas as restrições;
- **Variável “cópia”** $\hat{x} = x$ permite escrever $\mathcal{R}_1^F(x, \xi) = \max_{\hat{x}, y} d^\top y$
s.a. $T\hat{x} + Wy \leq h$
 $\hat{x} = x$ $[\pi]$
- Lagrangiano “parcial”: $\mathcal{L}(x, \xi; \hat{x}, y, \pi) = d^\top y + \pi^\top (x - \hat{x})$;
- Por **dualidade fraca**:

$$\mathcal{R}_1^F(x, \xi) \leq \bar{\pi}^\top x + \max_{\hat{x}, y} \{d^\top y - \bar{\pi}^\top \hat{x} : T\hat{x} + Wy \leq h\}.$$

- Se $\bar{\pi}$ é o multiplicador ótimo correspondente a $\bar{x}$, e se temos **dualidade forte**, então

$$\mathcal{R}_1^F(\bar{x}, \xi) = \bar{\pi}^\top \bar{x} + \max_{\hat{x}, y} \{d^\top y - \bar{\pi}^\top \hat{x} : T\hat{x} + Wy \leq h\}.$$

Dualidade via variável auxiliar

- Não queremos calcular multiplicadores para todas as restrições;
- **Variável “cópia”** $\hat{x} = x$ permite escrever $\mathcal{R}_1^F(x, \xi) = \max_{\hat{x}, y} d^\top y$
s.a. $T\hat{x} + Wy \leq h$
 $\hat{x} = x$ $[\pi]$
- Lagrangiano “parcial”: $\mathcal{L}(x, \xi; \hat{x}, y, \pi) = d^\top y + \pi^\top (x - \hat{x})$;
- Por **dualidade fraca**:

$$\mathcal{R}_1^F(x, \xi) \leq \bar{\pi}^\top x + \max_{\hat{x}, y} \{d^\top y - \bar{\pi}^\top \hat{x} : T\hat{x} + Wy \leq h\}.$$


- Se $\bar{\pi}$ é o multiplicador ótimo correspondente a $\bar{x}$, e se temos **dualidade forte**, então

$$\mathcal{R}_1^F(\bar{x}, \xi) = \bar{\pi}^\top \bar{x} + \max_{\hat{x}, y} \{d^\top y - \bar{\pi}^\top \hat{x} : T\hat{x} + Wy \leq h\}.$$


- Ou seja:

$$\mathcal{R}_1^F(x, \xi) - \mathcal{R}_1^F(\bar{x}, \xi) \leq \bar{\pi}^\top (x - \bar{x}).$$


Planos cortantes I: Função de Retorno




Planos cortantes I: Função de Retorno



Planos cortantes I: Função de Retorno



Planos cortantes I: Função de Retorno



Decomposição em cenários

$$\max_{x, y_i} \quad c^\top x + \sum_{i=1}^N p_i (d_i^\top y_i)$$

$$\text{s.a.} \quad Ax \leq b$$

$$T_i x + W_i y_i \leq h_i, \quad i = 1, \dots, N$$

Decomposição em cenários

$$\max_{x, y_i} \quad c^\top \mathbf{x} + \sum_{i=1}^N p_i (d_i^\top y_i)$$

$$\text{s.a.} \quad A\mathbf{x} \leq b$$

$$T_i \hat{x}_i + W_i y_i \leq h_i,$$

$$\hat{x}_i = \mathbf{x},$$

$$i = 1, \dots, N$$

$$i = 1, \dots, N$$

Decomposição em cenários

$$\begin{aligned} \max_{x, y_i} \quad & c^\top \mathbf{x} + \sum_{i=1}^N p_i (d_i^\top y_i) \\ \text{s.a.} \quad & A\mathbf{x} \leq b \\ & T_i \hat{x}_i + W_i y_i \leq h_i, & i = 1, \dots, N \\ & \hat{x}_i = \mathbf{x}, & [\pi_i] \quad i = 1, \dots, N \end{aligned}$$


Decomposição em cenários

$$\begin{aligned} \max_{x, y_i} \quad & c^\top \mathbf{x} + \sum_{i=1}^N p_i (d_i^\top y_i) \\ \text{s.a.} \quad & A\mathbf{x} \leq b \\ & T_i \hat{x}_i + W_i y_i \leq h_i, & i = 1, \dots, N \\ & \hat{x}_i = \mathbf{x}, & [\pi_i] \quad i = 1, \dots, N \end{aligned}$$

$$\begin{aligned} V(\mathbf{x}) &= \sum_{i=1}^N p_i \mathcal{R}_1^F(\mathbf{x}, \xi_i) \\ &\leq \sum_{i=1}^N p_i \left(\bar{\pi}_i^\top (\mathbf{x} - \bar{x}) + \mathcal{R}_1^F(\bar{x}, \xi_i) \right) \\ &= \left(\sum_{i=1}^N p_i \bar{\pi}_i \right)^\top (\mathbf{x} - \bar{x}) + V(\bar{x}). \end{aligned}$$


Planos cortantes II: Função Valor

3 cenários




Planos cortantes II: Função Valor

3 cenários




Planos cortantes II: Função Valor

201 cenários



Planos cortantes II: Função Valor

201 cenários



A função valor aproximada

- Para cada plano cortante, temos

$$V(x) \leq \bar{\pi}^\top (x - \bar{x}) + V(\bar{x}).$$

A função valor aproximada

- Para cada plano cortante, temos

$$V(x) \leq \bar{\pi}^\top (x - \bar{x}) + V(\bar{x}).$$


- Com K planos cortantes nos pontos $x^{(k)}$, a função

$$\hat{V}(x) = \min_{k=1,\dots,K} \left\{ \pi^{(k)\top} (x - x^{(k)}) + V(x^{(k)}) \right\}$$

também é maior do que $V(x)$, mas aproxima em *todos os pontos* $x^{(k)}$.


Planos cortantes III: Aproximação exterior

3 cenários




Planos cortantes III: Aproximação exterior

201 cenários




Planos cortantes III: Aproximação exterior

3 cenários



Planos cortantes III: Aproximação exterior

201 cenários



Algoritmo de Planos Cortantes

Decomposição

Problema do primeiro estágio

$$\max_x \quad c^\top x + V(x)$$

$$\text{s.a.} \quad Ax \leq b$$

Algoritmo de Planos Cortantes

Decomposição e Aproximação

Problema do primeiro estágio aproximado

$$\max_x \quad c^\top x + \hat{V}(x)$$

$$\text{s.a.} \quad Ax \leq b$$

$$\hat{V}(x) \leq \pi^{(k)\top} (x - x^{(k)}) + V(x^{(k)}) \quad k = 1, \dots, K$$

Algoritmo de Planos Cortantes

Decomposição e Aproximação

Problema do primeiro estágio aproximado

$$\max_x \quad c^\top x + \theta$$


$$\text{s.a.} \quad Ax \leq b$$

$$\theta \leq \pi^{(k)\top} (x - x^{(k)}) + V(x^{(k)}) \quad k = 1, \dots, K$$

onde θ é uma variável auxiliar para representar $\hat{V}(x)$.


Planos cortantes IV: Aproximação da função do primeiro estágio

3 cenários



Planos cortantes IV: Aproximação da função do primeiro estágio

201 cenários



Algoritmo de Planos Cortantes

1. Iniciar com $x^{(0)}$;

Algoritmo de Planos Cortantes

1. Iniciar com $x^{(0)}$;
2. Para $k = 0, 1, 2, \dots$:

Algoritmo de Planos Cortantes

1. Iniciar com $x^{(0)}$;
2. Para $k = 0, 1, 2, \dots$:
 - 2.1 Calcular $V(x^{(k)})$ e os multiplicadores ótimos $\bar{\pi}_i^{(k)}$ para cada cenário i ;

Algoritmo de Planos Cortantes

1. Iniciar com $x^{(0)}$;
2. Para $k = 0, 1, 2, \dots$:
 - 2.1 Calcular $V(x^{(k)})$ e os multiplicadores ótimos $\bar{\pi}_i^{(k)}$ para cada cenário i ;
 - 2.2 Adicionar o plano cortante

$$\theta \leq \left(\sum_{i=1}^N p_i \bar{\pi}_i^{(k)} \right)^{\top} (x - x^{(k)}) + V(x^{(k)});$$

Algoritmo de Planos Cortantes

1. Iniciar com $x^{(0)}$;
2. Para $k = 0, 1, 2, \dots$:
 - 2.1 Calcular $V(x^{(k)})$ e os multiplicadores ótimos $\bar{\pi}_i^{(k)}$ para cada cenário i ;
 - 2.2 Adicionar o plano cortante

$$\theta \leq \left(\sum_{i=1}^N p_i \bar{\pi}_i^{(k)} \right)^{\top} (x - x^{(k)}) + V(x^{(k)});$$

- 2.3 Resolver o problema do primeiro estágio com os planos cortantes adicionados, obtendo $x^{(k+1)}$ e $\hat{V}(x^{(k+1)})$.

Algoritmo de Planos Cortantes

1. Iniciar com $x^{(0)}$;
2. Para $k = 0, 1, 2, \dots$:
 - 2.1 Calcular $V(x^{(k)})$ e os multiplicadores ótimos $\bar{\pi}_i^{(k)}$ para cada cenário i ;
 - 2.2 Adicionar o plano cortante

$$\theta \leq \left(\sum_{i=1}^N p_i \bar{\pi}_i^{(k)} \right)^\top (x - x^{(k)}) + V(x^{(k)});$$

- 2.3 Resolver o problema do primeiro estágio com os planos cortantes adicionados, obtendo $x^{(k+1)}$ e $\hat{V}(x^{(k+1)})$.
3. Parar quando $\left| V(x^{(k)}) - \hat{V}(x^{(k)}) \right| \leq \epsilon$.

SIAM J. APPL. MATH.
Vol. 17, No. 4, July 1969

L*-SHAPED LINEAR PROGRAMS WITH APPLICATIONS TO OPTIMAL CONTROL AND STOCHASTIC PROGRAMMING

R. M. VAN SLYKE[†] AND ROGER WETS[‡]

Abstract. This paper gives an algorithm for *L*-shaped linear programs which arise naturally in optimal control problems with state constraints and stochastic linear programs (which can be represented in this form with an infinite number of linear constraints). The first section describes a cutting hyperplane algorithm which is shown to be equivalent to a partial decomposition algorithm of the dual program. The two last sections are devoted to applications of the cutting hyperplane algorithm to a linear optimal control problem and stochastic programming problems.

R. M. Van Slyke and Roger Wets, *L-Shaped Linear Programs with Applications to Optimal Control and Stochastic Programming*, SIAM Journal on Applied Mathematics, Vol. 17, No. 4 (Jul., 1969), pp. 638-663. <https://www.jstor.org/stable/2099310>

640

R. M. VAN SLYKE AND ROGER WETS

We give the name *L-shaped linear programs* to linear programs of the form :

Minimize

$$(1) \quad z = c^1 x + c^2 y$$

subject to

$$(1a) \quad A^{11}x = b^1,$$

$$(1b) \quad A^{21}x + A^{22}y = b^2,$$

$$x \geq 0, \quad y \geq 0,$$

R. M. Van Slyke and Roger Wets, *L-Shaped Linear Programs with Applications to Optimal Control and Stochastic Programming*, SIAM Journal on Applied Mathematics, Vol. 17, No. 4 (Jul., 1969), pp. 638-663. <https://www.jstor.org/stable/2099310>

5. Stochastic programs with recourse. A stochastic program with recourse (random right-hand sides) also known as two-stage linear programs under uncertainty [7] reads:

Minimize

$$(42) \quad z = cx + E_{\xi}\{\min qy\}$$

subject to

$$(42a) \quad Ax = b,$$

$$(42b) \quad Tx + Wy \geq \xi, \quad \xi \text{ on } (\Xi, z, F),$$

$$x \geq 0, \quad y \geq 0.$$

R. M. Van Slyke and Roger Wets, *L-Shaped Linear Programs with Applications to Optimal Control and Stochastic Programming*, SIAM Journal on Applied Mathematics, Vol. 17, No. 4 (Jul., 1969), pp. 638-663. <https://www.jstor.org/stable/2099310>

Plano

1. Função de Retorno: Propriedades
2. Função Valor e Decomposição em cenários
3. Dualidade e Algoritmos de planos cortantes para 2 estágios
4. *Aversão ao Risco*

Aversão ao Risco

- Até agora, consideramos apenas o retorno esperado:

$$V(x) = \mathbb{E}_{\xi} \left[\mathcal{R}_1^F(x, \xi) \right].$$

Aversão ao Risco

- Até agora, consideramos apenas o retorno esperado:

$$V(x) = \mathbb{E}_\xi \left[\mathcal{R}_1^F(x, \xi) \right].$$

- Em muitas aplicações, o tomador de decisão é *avesso ao risco*:
 - prefere evitar resultados ruins mesmo que isso implique em sacrificar o retorno esperado.

O problema de Markowitz

- x : investimento em cada ativo;
- ξ : vetor aleatório dos retornos dos ativos;
- $\mathcal{R}_1^F(x, \xi) = \xi^\top x$: retorno do portfólio.

O problema de Markowitz

- x : investimento em cada ativo;
- ξ : vetor aleatório dos retornos dos ativos;
- $\mathcal{R}_1^F(x, \xi) = \xi^\top x$: retorno do portfólio.
- Maximizando o retorno esperado, investimos apenas em um ativo.

O problema de Markowitz

- x : investimento em cada ativo;
- ξ : vetor aleatório dos retornos dos ativos;
- $\mathcal{R}_1^F(x, \xi) = \xi^\top x$: retorno do portfólio.
- Maximizando o retorno esperado, investimos apenas em um ativo.
- Equilibrando retorno esperado e risco (variância):

$$\begin{aligned} \max_x \quad & \mathbb{E}_\xi[\xi^\top x] - \lambda \text{Var}_\xi(\xi^\top x) \\ \text{s.a.} \quad & \sum x_i = 1 \\ & x \geq 0 \end{aligned}$$

onde $\lambda \geq 0$ é um parâmetro de aversão ao risco.

O problema de Markowitz


- x : investimento em cada ativo;
- ξ : vetor aleatório dos retornos dos ativos;
- $\mathcal{R}_1^F(x, \xi) = \xi^\top x$: retorno do portfólio.
- Maximizando o retorno esperado, investimos apenas em um ativo.
- Equilibrando retorno esperado e risco (variância):

$$\begin{aligned} \max_x \quad & \mathbb{E}_\xi[\xi^\top x] - \lambda \text{Var}_\xi(\xi^\top x) \\ \text{s.a.} \quad & \sum x_i = 1 \\ & x \geq 0 \end{aligned}$$


onde $\lambda \geq 0$ é um parâmetro de aversão ao risco.

- A função objetivo é côncava em x (bom para maximizar!).

A fronteira eficiente de Média-Variância



A fronteira eficiente de Média-Variância



De volta à utilidade

- Aversão ao risco via função utilidade:

$$V(x) = \mathbb{E}_{\xi} \left[U(\mathcal{R}_1^F(x, \xi)) \right],$$

onde U é uma função de utilidade *côncava*.

De volta à utilidade

- Aversão ao risco via função utilidade:

$$V(x) = \mathbb{E}_{\xi} \left[U(\mathcal{R}_1^F(x, \xi)) \right],$$

onde U é uma função de utilidade *côncava*.

- Exemplos

- logarítmica: $U(v) = \log(v)$, $v > 0$;
- potência: $U(v) = \frac{v^{1-\gamma}}{1-\gamma}$, $\gamma > 0, \gamma \neq 1$;
- exponencial: $U(v) = -e^{-\alpha v}$, $\alpha > 0$.

De volta à utilidade

- Aversão ao risco via função utilidade:

$$V(x) = \mathbb{E}_{\xi} \left[U(\mathcal{R}_1^F(x, \xi)) \right],$$

onde U é uma função de utilidade *côncava*.

- Exemplos

- logarítmica: $U(v) = \log(v)$, $v > 0$;
- potência: $U(v) = \frac{v^{1-\gamma}}{1-\gamma}$, $\gamma > 0, \gamma \neq 1$;
- exponencial: $U(v) = -e^{-\alpha v}$, $\alpha > 0$.

- Como U é côncava, a desigualdade de Jensen dá

$$V(x) = \mathbb{E}_{\xi} \left[U(v_{\xi}) \right] \leq U\left(\mathbb{E}_{\xi}[v_{\xi}]\right).$$

Um *retorno incerto* é pior do que um *retorno certo* com a mesma média.

Medidas de Risco

- Uma medida de risco ρ transforma uma variável aleatória Z (representando um custo ou perda) em um único valor real $\rho[Z]$ (para ser otimizado);
- Generalização do valor esperado $\mathbb{E}[Z]$.

Medidas de Risco

- Uma medida de risco ρ transforma uma variável aleatória Z (representando um custo ou perda) em um único valor real $\rho[Z]$ (para ser otimizado);
- Generalização do valor esperado $\mathbb{E}[Z]$.

Medidas Coerentes de Risco [Artzner et al., 1999]

- Monotonicidade: se $Z_1(\xi) \leq Z_2(\xi)$, então $\rho_\xi[Z_1(\xi)] \leq \rho_\xi[Z_2(\xi)]$
- Superaditividade: $\rho_\xi[Z_1(\xi) + Z_2(\xi)] \geq \rho_\xi[Z_1(\xi)] + \rho_\xi[Z_2(\xi)]$
- Homogeneidade positiva: para $\lambda \geq 0$, $\rho_\xi[\lambda Z(\xi)] = \lambda \rho_\xi[Z(\xi)]$
- Invariância por translação: para $a \in \mathbb{R}$, $\rho_\xi[Z(\xi) + a] = \rho_\xi[Z(\xi)] + a$

Medidas de Risco

- Uma medida de risco ρ transforma uma variável aleatória Z (representando um custo ou perda) em um único valor real $\rho[Z]$ (para ser otimizado);
- Generalização do valor esperado $\mathbb{E}[Z]$.

Medidas Coerentes de Risco [Artzner et al., 1999]

- Monotonicidade: se $Z_1(\xi) \leq Z_2(\xi)$, então $\rho_\xi[Z_1(\xi)] \leq \rho_\xi[Z_2(\xi)]$
- Superaditividade: $\rho_\xi[Z_1(\xi) + Z_2(\xi)] \geq \rho_\xi[Z_1(\xi)] + \rho_\xi[Z_2(\xi)]$
- Homogeneidade positiva: para $\lambda \geq 0$, $\rho_\xi[\lambda Z(\xi)] = \lambda \rho_\xi[Z(\xi)]$
- Invariância por translação: para $a \in \mathbb{R}$, $\rho_\xi[Z(\xi) + a] = \rho_\xi[Z(\xi)] + a$
- Superaditividade + Homogeneidade $\Rightarrow$ Concavidade.

Medidas de Risco

- Uma medida de risco ρ transforma uma variável aleatória Z (representando um custo ou perda) em um único valor real $\rho[Z]$ (para ser otimizado);
- Generalização do valor esperado $\mathbb{E}[Z]$.

Medidas Coerentes de Risco [Artzner et al., 1999]

- Monotonicidade: se $Z_1(\xi) \leq Z_2(\xi)$, então $\rho_\xi[Z_1(\xi)] \leq \rho_\xi[Z_2(\xi)]$
- Superaditividade: $\rho_\xi[Z_1(\xi) + Z_2(\xi)] \geq \rho_\xi[Z_1(\xi)] + \rho_\xi[Z_2(\xi)]$
- Homogeneidade positiva: para $\lambda \geq 0$, $\rho_\xi[\lambda Z(\xi)] = \lambda \rho_\xi[Z(\xi)]$
- Invariância por translação: para $a \in \mathbb{R}$, $\rho_\xi[Z(\xi) + a] = \rho_\xi[Z(\xi)] + a$
- Superaditividade + Homogeneidade $\Rightarrow$ Concavidade.
 - Combina bem com problemas de *maximização de retorno*;

Medidas de Risco

- Uma medida de risco ρ transforma uma variável aleatória Z (representando um custo ou perda) em um único valor real $\rho[Z]$ (para ser otimizado);
- Generalização do valor esperado $\mathbb{E}[Z]$.

Medidas Coerentes de Risco [Artzner et al., 1999]

- Monotonicidade: se $Z_1(\xi) \leq Z_2(\xi)$, então $\rho_\xi[Z_1(\xi)] \leq \rho_\xi[Z_2(\xi)]$
- Superaditividade: $\rho_\xi[Z_1(\xi) + Z_2(\xi)] \geq \rho_\xi[Z_1(\xi)] + \rho_\xi[Z_2(\xi)]$
- Homogeneidade positiva: para $\lambda \geq 0$, $\rho_\xi[\lambda Z(\xi)] = \lambda \rho_\xi[Z(\xi)]$
- Invariância por translação: para $a \in \mathbb{R}$, $\rho_\xi[Z(\xi) + a] = \rho_\xi[Z(\xi)] + a$
- Superaditividade + Homogeneidade $\Rightarrow$ Concavidade.
 - Combina bem com problemas de *maximização de retorno*;
 - Para *minimização de custos*, as medidas coerentes de risco são *subaditivas* (e convexas).

Medidas de Risco

Exemplos

- Valor em Risco (VaR), ou α -quantil (não é coerente!);

Medidas de Risco

Exemplos

- Valor em Risco (VaR), ou α -quantil (não é coerente!);
- Valor Condicional em Risco (CVaR):
 - Média dos α *piores cenários* (menores retornos, ao maximizar; maiores custos, ao minimizar),
 - mais conservador do que o VaR;

Medidas de Risco

Exemplos


- Valor em Risco (VaR), ou α -quantil (não é coerente!);
- Valor Condicional em Risco (CVaR):
 - Média dos α *piores cenários* (menores retornos, ao maximizar; maiores custos, ao minimizar),
 - mais conservador do que o VaR;
- Valor em Risco Entropicamente Regularizado (EVaR):
 - Baseado na desigualdade de Chernoff;
 - Mais conservador do que o CVaR.

Medidas de Risco


Exemplos

- Valor em Risco (VaR), ou α -quantil (não é coerente!);
- Valor Condicional em Risco (CVaR):
 - Média dos α *piores cenários* (menores retornos, ao maximizar; maiores custos, ao minimizar),
 - mais conservador do que o VaR;
- Valor em Risco Entropicamente Regularizado (EVaR):
 - Baseado na desigualdade de Chernoff;
 - Mais conservador do que o CVaR.
- Combinações convexas, por exemplo $\rho = (1 - \lambda)\mathbb{E} + \lambda\text{CVaR}_\alpha$.


O CVaR



O CVaR



O CVaR




Uma equação para o CVaR

Retorno R : r_j com probabilidade p_j :

$$\begin{aligned}\text{CVaR}_\alpha(R) \\ &= \text{VaR}_\alpha(R) - \frac{1}{\alpha} \mathbb{E} \left[(R - \text{VaR}_\alpha(R))^- \right]\end{aligned}$$

O CVaR




Uma equação para o CVaR

Retorno R : r_j com probabilidade p_j :

$$\begin{aligned}\text{CVaR}_\alpha(R) &= \text{VaR}_\alpha(R) - \frac{1}{\alpha} \mathbb{E} \left[(R - \text{VaR}_\alpha(R))^- \right] \\ &= \text{VaR}_\alpha(R) - \frac{1}{\alpha} \mathbb{E}[w] \\ &\quad w \geq 0, \\ &\quad w \geq \text{VaR}_\alpha(R) - R\end{aligned}$$

O CVaR



Um PL para o CVaR

Retorno R : r_j com probabilidade p_j :

$$\begin{aligned} \text{CVaR}_\alpha(R) \\ = \max_{z, w_j} \quad & z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j \\ \text{s.a.} \quad & z - w_j \leq r_j, \\ & w_j \geq 0. \end{aligned}$$

[Rockafellar e Uryasev, 2000]

O Jornaleiro com CVaR

$$\begin{aligned} \max_x \quad & -cx + \text{CVaR}_\alpha[\mathcal{R}_1^F(x, \xi)] \\ \text{s.a.} \quad & 0 \leq x \leq \bar{x} \end{aligned}$$

O Jornaleiro com CVaR

$$\begin{aligned} \max_x \quad & -cx + \text{CVaR}_\alpha[\mathcal{R}_1^F(x, \xi)] \\ \text{s.a.} \quad & 0 \leq x \leq \bar{x} \end{aligned}$$

Função valor:

$$\begin{aligned} V(x) = \max_{z, w_j, r_j, y_j, z_j} \quad & z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j \\ \text{s.a.} \quad & z - w_j \leq r_j, & j = 1, \dots, N \\ & w_j \geq 0, & j = 1, \dots, N \end{aligned}$$

O Jornaleiro com CVaR

$$\begin{aligned} \max_x \quad & -cx + \text{CVaR}_\alpha[\mathcal{R}_1^F(x, \xi)] \\ \text{s.a.} \quad & 0 \leq x \leq \bar{x} \end{aligned}$$

Função valor:

$$\begin{aligned} V(x) = \quad & \max_{z, w_j, r_j, y_j, z_j} \quad z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j \\ \text{s.a.} \quad & z - w_j \leq r_j, & j = 1, \dots, N \\ & w_j \geq 0, & j = 1, \dots, N \\ & r_j = qy_j + rz_j, & j = 1, \dots, N \\ & y_j + z_j \leq x, & j = 1, \dots, N \\ & 0 \leq y_j \leq d_j, \quad 0 \leq z_j & j = 1, \dots, N \end{aligned}$$


O Jornaleiro com CVaR

$$\begin{aligned} \max_x \quad & -cx + \text{CVaR}_\alpha[\mathcal{R}_1^F(x, \xi)] \\ \text{s.a.} \quad & 0 \leq x \leq \bar{x} \end{aligned}$$

Função valor:

$$\begin{aligned} V(x) = \quad & \max_{z, w_j, r_j, y_j, z_j} \quad z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j \\ \text{s.a.} \quad & z - w_j \leq r_j, & j = 1, \dots, N \\ & w_j \geq 0, & j = 1, \dots, N \\ & \mathcal{R}_1^F(x, \xi_j) \begin{cases} r_j = qy_j + rz_j, & j = 1, \dots, N \\ y_j + z_j \leq x, & j = 1, \dots, N \\ 0 \leq y_j \leq d_j, \quad 0 \leq z_j & j = 1, \dots, N \end{cases} \end{aligned}$$

O Jornaleiro com CVaR



Planos cortantes com CVaR

Dualidade

$$\begin{aligned} \bullet \text{ CVaR}_\alpha(R) = & \max_{z, w_j} \quad z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j \\ & \text{s.a.} \quad z - w_j \leq r_j, & [\mu_j \leq 0] \\ & \quad w_j \geq 0 & [\nu_j \geq 0]. \end{aligned}$$

Planos cortantes com CVaR

Dualidade

- $\text{CVaR}_\alpha(R) = \max_{z, w_j} z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j$
s.a. $z - w_j \leq r_j, \quad [\mu_j \leq 0]$
 $w_j \geq 0 \quad [\nu_j \geq 0].$
- Lagrangiano: $\mathcal{L}(z, w_j, \mu_j, \nu_j) = z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j + \sum_{j=1}^N \mu_j (z - w_j - r_j) + \sum_{j=1}^N \nu_j w_j$

Planos cortantes com CVaR

Dualidade

- $\text{CVaR}_\alpha(R) = \max_{z, w_j} z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j$
s.a. $z - w_j \leq r_j, \quad [\mu_j \leq 0]$
 $w_j \geq 0 \quad [\nu_j \geq 0].$
- Lagrangiano: $\mathcal{L}(z, w_j, \mu_j, \nu_j) = z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j + \sum_{j=1}^N \mu_j (z - w_j - r_j) + \sum_{j=1}^N \nu_j w_j$
$$= \left(1 + \sum_{j=1}^N \mu_j\right) z + \sum_{j=1}^N \left(\nu_j - \frac{p_j}{\alpha} - \mu_j\right) w_j - \sum_{j=1}^N \mu_j r_j.$$

Planos cortantes com CVaR

Dualidade

- $\text{CVaR}_\alpha(R) = \max_{z, w_j} z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j$
s.a. $z - w_j \leq r_j, \quad [\mu_j \leq 0]$
 $w_j \geq 0 \quad [\nu_j \geq 0].$
- Lagrangiano: $\mathcal{L}(z, w_j, \mu_j, \nu_j) = z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j + \sum_{j=1}^N \mu_j (z - w_j - r_j) + \sum_{j=1}^N \nu_j w_j$
$$= \left(1 + \sum_{j=1}^N \mu_j\right) z + \sum_{j=1}^N \left(\nu_j - \frac{p_j}{\alpha} - \mu_j\right) w_j - \sum_{j=1}^N \mu_j r_j.$$
- Função dual: $g(\mu_j, \nu_j) = \begin{cases} -\sum_{j=1}^N \mu_j r_j, & 1 + \sum_{j=1}^N \mu_j = 0, \\ \nu_j - \frac{p_j}{\alpha} - \mu_j = 0, & j = 1, \dots, N \\ +\infty, & \text{caso contrário.} \end{cases}$

Planos cortantes com CVaR

Dualidade

- $\text{CVaR}_\alpha(R) = \max_{z, w_j} z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j$
s.a. $z - w_j \leq r_j, \quad [\mu_j \leq 0]$
 $w_j \geq 0 \quad [\nu_j \geq 0].$
- Lagrangiano: $\mathcal{L}(z, w_j, \mu_j, \nu_j) = z - \frac{1}{\alpha} \sum_{j=1}^N p_j w_j + \sum_{j=1}^N \mu_j (z - w_j - r_j) + \sum_{j=1}^N \nu_j w_j$
$$= \left(1 + \sum_{j=1}^N \mu_j\right) z + \sum_{j=1}^N \left(\nu_j - \frac{p_j}{\alpha} - \mu_j\right) w_j - \sum_{j=1}^N \mu_j r_j.$$
- Função dual: $g(\tilde{\mu}_j) = \begin{cases} \sum_{j=1}^N \tilde{\mu}_j r_j, & 1 = \sum_{j=1}^N \tilde{\mu}_j, \\ \tilde{\mu}_j \leq \frac{p_j}{\alpha}, & j = 1, \dots, N \\ +\infty, & \text{caso contrário.} \end{cases}$

Planos cortantes com CVaR

- Mesma lógica: construir cortes para $\mathcal{R}_1^F(x, \xi_j)$ em cada cenário j :

$$\mathcal{R}_1^F(x, \xi_j) \leq \bar{\pi}_j^\top (x - \bar{x}) + \mathcal{R}_1^F(\bar{x}, \xi_j).$$

Planos cortantes com CVaR

- Mesma lógica: construir cortes para $\mathcal{R}_1^F(x, \xi_j)$ em cada cenário j :

$$\mathcal{R}_1^F(x, \xi_j) \leq \bar{\pi}_j^\top (x - \bar{x}) + \mathcal{R}_1^F(\bar{x}, \xi_j).$$

- $V(x)$ é menor do que a média ponderada de *quaisquer* cenários cuja soma das probabilidades é α .

Planos cortantes com CVaR

- Mesma lógica: construir cortes para $\mathcal{R}_1^F(x, \xi_j)$ em cada cenário j :

$$\mathcal{R}_1^F(x, \xi_j) \leq \bar{\pi}_j^\top (x - \bar{x}) + \mathcal{R}_1^F(\bar{x}, \xi_j).$$

- $V(x)$ é menor do que a média ponderada de *quaisquer* cenários cuja soma das probabilidades é α .
- O corte para o $V(x) = \text{CVaR}[R]$ será a *média ponderada* dos cortes dos cenários:

$$V(x) \leq \left(\sum_{j=1}^N \tilde{p}_j \bar{\pi}_j \right)^\top (x - \bar{x}) + V(\bar{x}),$$

$$\text{onde } \tilde{p}_j = \begin{cases} p_j/\alpha, & \text{se } \mathcal{R}_1^F(\bar{x}, \xi_j) < \bar{q}, \\ 0, & \text{se } \mathcal{R}_1^F(\bar{x}, \xi_j) > \bar{q}, \\ \text{o restante} & \text{se } \mathcal{R}_1^F(\bar{x}, \xi_j) = \bar{q}, \end{cases}$$

Referências

- A. Shapiro and A. Philpott. *A Tutorial on Stochastic Programming*.
<https://citeseerx.ist.psu.edu/document?repid=rep1&type=pdf&doi=b8c94a3fb92448275fde0dbe8227d37fb47a4f58>
- R. M. Van Slyke and Roger Wets. *L-Shaped Linear Programs with Applications to Optimal Control and Stochastic Programming*. SIAM Journal on Applied Mathematics, Vol. 17, No. 4 (Jul., 1969), pp. 638-663.
- H. Markowitz. *Portfolio Selection*. The Journal of Finance, 7(1):77–91, 1952.
- P. Artzner, F. Delbaen, J.-M. Eber, and D. Heath. *Coherent Measures of Risk*. Mathematical Finance, 9(3):203–228, 1999.
- R. T. Rockafellar and S. Uryasev. *Optimization of Conditional Value-at-Risk*. Journal of Risk, 2(3): 21–41, 2000.
- J. R. Birge and F. Louveaux. *Introduction to Stochastic Programming*. Springer, 2011.
- A. Shapiro, D. Dentcheva, and A. Ruszczyński. *Lectures on Stochastic Programming: Modeling and Theory*. 3rd Ed., SIAM, 2021.