

Tomada de decisão sequencial sob incerteza sem árvores de cenários

Bernardo K. Pagnoncelli

SKEMA Business School, Lille, France

Curso de otimização estocástica – Aula 3
SOBRAPO, 2025

Outline

Introdução

O mundo dos Processos de Decisão de Markov (MDPs)

CACS: Uma introdução aos grafos de políticas (PG)

Exemplos práticos

Dependência na decisão

Risco

Conclusões

Outline

Introdução

O mundo dos Processos de Decisão de Markov (MDPs)

CACS: Uma introdução aos grafos de políticas (PG)

Exemplos práticos

Dependência na decisão

Risco

Conclusões

Por que decisões sequenciais?

- ▶ Muitos problemas reais envolvem **decisões em vários momentos**, com novas informações reveladas ao longo do tempo.
- ▶ Modelos de duas etapas (*two-stage*) capturam apenas uma única oportunidade de ajustar a decisão inicial.
- ▶ Em diversos contextos—controle, energia, finanças, operações, política econômica—é necessário **reagir sequencialmente** às incertezas.
- ▶ Ignorar a estrutura sequencial pode levar a decisões **subótimas**
- ▶ Má notícia: resolver o problema sequencial é bem mais difícil
- ▶ Se queremos entender melhor o compromisso entre **ganhos presentes** e **ganhos futuros**, temos que lidar com este tipo de problema

DADS vs. CACS

- ▶ Problemas dinâmicos, tomada de decisão sequencial ou otimização estocástica multietapas têm sido uma área de pesquisa muito ativa nos últimos anos.
- ▶ Uma abordagem bastante popular para lidar com esses problemas é o *MDP* (Processo de Decisão de Markov). No entanto, na maioria dos casos, o espaço de ações e o espaço de estados são discretos (**DADS**).
- ▶ No famoso livro de MDP de Puterman (~ 20.000 citações!), o único exemplo que encontrei com espaço de ações e estados contínuos (**CACS**) tem solução em forma fechada.
- ▶ Em geral, problemas dinâmicos não possuem soluções em forma fechada: pesquisadores têm desenvolvido algoritmos numéricos capazes de gerar boas políticas de forma eficiente.

Algumas Referências

- ▶ Porteus, E. L. (2002). *Foundations of Stochastic Inventory Theory*. Stanford University Press.
- ▶ Puterman, M. L. (2005). *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. Wiley.
- ▶ Alessandro Lazaric. *Course on Reinforcement Learning*. Disponível em: https://chercheurs.lille.inria.fr/lazaric/Webpage/MVA-RL_Course15.html
- ▶ Dowson, O., & Morton, D. P. (2020). *Partially Observable Multistage Stochastic Programming*. *Operations Research Letters*.
- ▶ Dowson, O., & Morton, D. P. (2022). *Incorporating Convex Risk Measures into Multistage Stochastic Programming Algorithms*. *Annals of Operations Research*.
- ▶ Morton, D. P., & Dowson, O. (2025). *MDP Modeling for Multistage Stochastic Programs*. Under review. Disponível em: <https://www.arxiv.org/abs/2509.22981>
- ▶ The SDDP.jl package: <https://sddp.dev/stable/>

Essa aula

- ▶ Meu objetivo principal é dar uma ampla introdução a diferentes classes de problemas dinâmicos
- ▶ O foco vão ser exemplos que ilustram a teoria
- ▶ Eu vou falar de uma estrutura + algoritmo bastante gerais, com um foco em problemas do tipo CACS
- ▶ Muitos problemas relevantes na prática podem ser resolvidos com estas ferramentas, mas existem limitações
- ▶ Vamos começar!



Outline

Introdução

O mundo dos Processos de Decisão de Markov (MDPs)

CACS: Uma introdução aos grafos de políticas (PG)

Exemplos práticos

Dependência na decisão

Risco

Conclusões

Uma introdução aos MDPs

- ▶ Os MDPs são a ferramenta mais popular para modelar problemas de tomada de decisão sequencial sob incerteza
- ▶ Os MDPs são o ponto de partida do *Aprendizado por Reforço* (*Reinforcement Learning*), e aplicações como o *AlphaGo Zero* fazem uso extensivo desse arcabouço
- ▶ Primeiro, precisamos concordar sobre a notação; em seguida, estudaremos as diferentes classes de problemas nesse contexto

Terminologia

- Um processo de decisão de Markov (MDP) é definido como uma tupla $(\mathcal{X}, \mathcal{U}, p, C)$, onde:

1. $\mathcal{X}$ é o espaço de estados

2. $\mathcal{U}$ é o espaço de ações


3. $p(x' | x, u)$ é a probabilidade de transição, com

$$p(x' | x, u) = \mathbb{P}(x_{t+1} = x' | x_t = x, u_t = u)$$

4. $C(x, u, x')$ é o custo (ou recompensa) associado à transição (x, u, x')

- Uma **regra de decisão** é uma aplicação: $\pi_t : \mathcal{X} \mapsto \mathcal{U}$

- Uma **política** é um conjunto de regras de decisão
 $\pi = \{\pi_t : t = 1, 2, \dots, T\}$



Classes de problemas

Qualquer um desses problemas pode ser:

1. Determinístico ou estocástico
 2. CACS ou DADS
 3. Neutro ao risco ou avesso ao risco
- ▶ **Horizonte de tempo finito T :** o agente busca maximizar a soma das recompensas até T .
 - ▶ **Horizonte de tempo infinito com desconto:** recompensas que estão mais *próximas* no tempo recebem uma *maior importância*.
 - ▶ **Horizonte de tempo infinito com estados absorventes:** o agente eventualmente alcança um *estado de terminação*.
 - ▶ **Horizonte de tempo infinito com recompensa média:** o agente se concentra apenas na (esperança da) *média das recompensas*.

Horizonte de tempo finito T

$$V_t(x) = \max_{u \in \mathcal{U}(x)} \left\{ C(x, u) + \alpha \sum_{j \in \mathcal{X}} p_{xj}^u V_{t+1}(j) \right\},$$

onde $V_{T+1} := v^T(j)$ para todo $j \in \mathcal{X}$.

- ▶ Esta é, de longe, a classe mais popular de MDPs.
- ▶ Aplicações típicas incluem problemas de manutenção, gestão de estoques, sistemas de filas e serviços, robótica, manufatura, saúde, telecomunicações e gestão de recursos naturais.
- ▶ Não focaremos nesses problemas neste curso.
- ▶ Para esse tipo de problema (horizonte finito), o algoritmo mais comum é a *indução regressiva* (*backward induction*)

Problemas com estados absorventes

- ▶ Em muitos processos de decisão sequenciais, o episódio *termina* ao atingir um estado final:

$$X_t \rightarrow X_{t+1} = x_{\text{abs}}, \quad V(x_{\text{abs}}) = v_{\text{terminal}}.$$

- ▶ Esse estado pode representar *sucesso, falha, abandono, morte, conclusão, ou absorção física*.

Exemplos clássicos:

- ▶ Falência ou *ruína financeira*
- ▶ Falha definitiva de equipamento
- ▶ Cliente abandona o serviço (*churn*)
- ▶ Navegação até o alvo (ou colisão)


Outros domínios:

- ▶ Parada ótima (*aceitar oferta*)
- ▶ Tratamento médico: cura ou óbito
- ▶ Erradicação de epidemia
- ▶ Controle de risco/extinção ecológica

Modelagem típica

$$V(x) = r(x, a) + \sum_{x'} p_{xx'}^u V(x'), \quad V(x_{\text{abs}}) = v_{\text{terminal}}.$$

Horizonte de tempo infinito com estados absorventes



Horizonte infinito com desconto (DADS)

- ▶ Espaço de estados: $\mathcal{X} = \{1, 2, \dots, X\}$
- ▶ Conjunto de ações admissíveis $\mathcal{U}(x)$
- ▶ Conjunto de regras de decisão admissíveis $\delta \in \Delta$
- ▶ Para todo x e $u \in \mathcal{U}(x)$, existe $\delta \in \Delta$ tal que $\delta(x) = u$
- ▶ Estratégia $\pi = (\pi_1, \dots, \pi_N)$, em que π_t é uma regra de decisão no período t
- ▶ v_T é a função valor terminal no último período N , e $v_t(\pi, x)$ é o valor presente esperado ao iniciar o período t no estado x seguindo a estratégia π

Programação linear

Considere o seguinte problema¹ primal (P):

$$\min_v e^\top v$$

sujeito a

$$C(x, u) + \sum_{j \in \mathcal{X}} q_{xj}^u v_j \leq v_x \quad \text{para todo } x \in \mathcal{X}, u \in \mathcal{U}(x).$$

Lema

- (a) A função valor ótima V é viável para (P).
- (b) Se v é viável para (P), então $v \geq V$.
- (c) A função valor ótima V é a única solução ótima de (P).

¹ $q = \alpha p$

Dualidade

Reescrevendo (P):

$$\min_v \sum_{x \in \mathcal{X}} v_x$$

sujeito a

$$C(x, u) + \sum_{j \in \mathcal{X}} q_{xj}^u v_j \leq v_x, \quad \forall x \in \mathcal{X}, \forall u \in \mathcal{U}(x).$$

Esse problema de PL possui $|\mathcal{X}|$ variáveis de decisão e uma restrição para cada combinação estado/ação viável. Na prática, é mais conveniente (por quê?) resolver o **dual**:

$$\max_x \sum_{x \in \mathcal{X}} \sum_{u \in \mathcal{U}(x)} C(x, u) z_x^u$$

sujeito a

$$\sum_{u \in \mathcal{U}(x)} z_x^u - \sum_{i \in \mathcal{X}} \sum_{u \in \mathcal{U}(i)} q_{ix}^u z_i^u = 1, \quad \forall x \in \mathcal{X}, \quad z_x^u \geq 0.$$

1. As variáveis z_x^u estritamente positivas na solução ótima indicam as ações ótimas no MDP.
2. Os multiplicadores (preços sombra) na solução ótima do dual fornecem os valores ótimos V_x para cada estado.

Exercício prático: e-Rite-Way

Você administra uma empresa de varejo online chamada *e-Rite-Way*. Seus clientes anteriores podem estar no *estado 1* (inativos, sem compras no último mês) ou no *estado 2* (ativos). Agora você está considerando enviar um brinde, com uma promoção pequena (\$1) ou grande (\$5) para um produto que custa \$8. Assuma um fator de desconto de $\alpha = 0.99$.

Decisão	Descrição	Custo direto (\$)
0	Nenhuma ação	0
1	Brinde + promoção pequena	0,50
2	Brinde + promoção grande	0,50

Estado	Decisão	Prob. sem compra	Prob. de compra
s	a	p_{s1}^a	p_{s2}^a
1	0	0.9899	0.0101
1	1	0.9293	0.0707
1	2	0.8586	0.1414
2	0	0.8081	0.1919
2	1	0.7273	0.2727
2	2	0.5051	0.4949

Tabela: Probabilidades de compra

e-Rite-Way (cont.)

$$r(s, a) := -c(a) + \alpha \sum_j p_{sj}^a r_{sj}^a,$$

onde $r_{s2}^0 = 8$, $r_{s2}^1 = 7$ e $r_{s2}^2 = 3$ (os demais são zero).

Estado	Decisão	Custo direto (\$)	Valor presente esperado da compra (\$)	Retorno imediato (\$)
1	0	0	.99[(.9899)0 + (0.0101)8]	0.08
1	1	-0.5	.99[(.9293)0 + (0.0707)7]	-0.01
1	2	-0.5	.99[(.8586)0 + (0.1414)3]	-0.08
2	0	0	.99[(.8081)0 + (0.1919)8]	1.52
2	1	-0.5	.99[(.7273)0 + (0.2727)7]	1.39
2	2	-0.5	.99[(.5051)0 + (0.4949)3]	0.97

Tabela: Retornos imediatos esperados

Conclusão?

e-Rite-Way (cont.)

$$r(s, a) := -c(a) + \alpha \sum_j p_{sj}^a r_{sj}^a,$$

onde $r_{s2}^0 = 8$, $r_{s2}^1 = 7$ e $r_{s2}^2 = 3$ (os demais são zero).

Estado	Decisão	Custo direto (\$)	Valor presente esperado da compra (\$)	Retorno imediato (\$)
1	0	0	.99[(.9899)0 + (0.0101)8]	0.08
1	1	-0.5	.99[(.9293)0 + (0.0707)7]	-0.01
1	2	-0.5	.99[(.8586)0 + (0.1414)3]	-0.08
2	0	0	.99[(.8081)0 + (0.1919)8]	1.52
2	1	-0.5	.99[(.7273)0 + (0.2727)7]	1.39
2	2	-0.5	.99[(.5051)0 + (0.4949)3]	0.97

Tabela: Retornos imediatos esperados

Conclusão? **Não envie nada a ninguém!**

Devido ao horizonte curto, podemos estar ignorando o valor de converter clientes inativos em ativos, que são mais propensos a comprar novamente.

Exercício: resolva a versão de horizonte infinito deste problema.

Dados úteis

Estado	Decisão	Prob. sem compra	Prob. de compra
s	a	q_{s1}^a	q_{s2}^a
1	0	0.98	0.01
1	1	0.92	0.07
1	2	0.85	0.14
2	0	0.80	0.19
2	1	0.72	0.27
2	2	0.50	0.49

Tabela: Probabilidades de transição efetivas

Estado	Decisão	Custo direto (\$)	Valor presente esperado (\$)	Retorno imediato (\$)
1	0	0	$.99[(.9899)0 + (0.0101)8]$	0.08
1	1	-0.5	$.99[(.9293)0 + (0.0707)7]$	-0.01
1	2	-0.5	$.99[(.8586)0 + (0.1414)3]$	-0.08
2	0	0	$.99[(.8081)0 + (0.1919)8]$	1.52
2	1	-0.5	$.99[(.7273)0 + (0.2727)7]$	1.39
2	2	-0.5	$.99[(.5051)0 + (0.4949)3]$	0.97

Tabela: Retornos imediatos esperados

Outline

Introdução

O mundo dos Processos de Decisão de Markov (MDPs)

CACS: Uma introdução aos grafos de políticas (PG)

Exemplos práticos

Dependência na decisão

Risco

Conclusões

Definições

- ▶ Um **estágio** é um momento discreto no tempo em que o agente escolhe uma decisão e a incerteza é revelada.
- ▶ Um **ruído** é uma variável aleatória no estágio t .
- ▶ Um **estado** é uma função do histórico que captura a informação necessária para modelar o sistema em um estágio t .
- ▶ Uma **variável de controle** é uma ação ou decisão tomada (explicitamente ou implicitamente) pelo agente durante um estágio.
- ▶ A **função de transição** é uma aplicação que mapeia o estado de entrada x_t para o estado de saída x'_t , dado o controle u_t e o ruído ω_t :

$$x'_t = T_t(x_t, u_t, \omega_t).$$

- ▶ O **objetivo de estágio** é o custo, no estágio t , de tomar o controle u_t , dado o estado de entrada x_t e a realização do ruído ω_t .
- ▶ Uma **regra de decisão** π_t , para o estágio t , é uma aplicação que associa o estado de entrada x_t e a observação do ruído ω_t a um controle u_t .
- ▶ Uma **política** é um conjunto de regras de decisão $\pi = \{\pi_t : t = 1, 2, \dots, T\}$.

Discussão: MDPs vs. Otimização Estocástica

MDP

- ▶ Espaço de estados **discreto**
- ▶ Dinâmica definida por **probabilidades de transição**:

$$p(x'|x, u)$$

- ▶ O ruído é **implícito**: incerteza embutida nas probabilidades
- ▶ Ideal para ambientes com poucos estados e ações

Otimização Estocástica

- ▶ Espaço de estados **contínuo** ou de alta dimensão
- ▶ Dinâmica definida por uma **função de transição**:

$$x' = T(x, u, \omega)$$

- ▶ O ruído ω é **explícito**, com distribuição conhecida
- ▶ Mais natural para CACS

Equivalência conceitual


$$p(x'|x, u) = \mathbb{P}(T(x, u, \omega) = x')$$

Resumo





Ambos descrevem a mesma lógica dinâmica: o que muda é **a granularidade da incerteza e a forma de representá-la**.

Grafo de políticas

Um **grafo de políticas**, $\mathcal{G} = (R, \mathcal{N}, \mathcal{E}, \Phi)$, é uma tupla com um nó raiz R , um conjunto de nós $\mathcal{N}$ e um conjunto de arestas direcionadas $\mathcal{E}$. A matriz Φ , de dimensão $(|\mathcal{N}| + 1) \times |\mathcal{N}|$, contém as probabilidades de transição entre os nós, com entradas $\Phi = (\phi_{ij})$.



Exemplos de PG



O problema de otimização dinâmica com PG

A função de *custo futuro* (cost-to-go) em um nó $i \in \mathcal{N}$ é dada por

$$V_i(x, \omega_i) = \min_{u, x'} \left\{ C_i(u, x', \omega_i) + \mathbb{E}_{j \in i^+; \omega_j} [V_j(x', \omega_j)] \right\}$$

sujeito a $(u, x') \in \mathcal{X}_i(x, \omega_i),$

onde

$$\mathbb{E}_{j \in i^+; \omega_j} [V_j(x', \omega_j)] = \sum_{j \in i^+} \phi_{ij} \sum_{\omega \in \Omega_j} \mathbb{P}_j(\omega) \cdot V_j(x', \omega).$$

O problema global pode ser escrito como:

$$\min_{\pi \in \Pi} \mathbb{E}_{i \in R^+; \omega_i} [V_i(x_R, \omega_i)].$$

Ideia geral do algoritmo SDDP

- ▶ O **SDDP**² (*Stochastic Dual Dynamic Programming*) é um método para resolver **problemas de decisão sequencial sob incerteza**.
- ▶ Ele é especialmente útil para problemas CACS quando o horizonte é longo (ou infinito) e o número de cenários é muito grande.
- ▶ Em vez de explorar todas as possibilidades de realização da incerteza, o SDDP **usa amostras** e **aproxima** as funções de valor em cada estágio.
- ▶ A ideia central: alternar entre **simulações para frente** e **aproximações para trás**.

²Pereira & Pinto '91

Fases do SDDP

1. Passo *forward*

- ▶ O algoritmo **simula cenários** de incerteza.
- ▶ Para cada cenário, ele **toma decisões** usando a aproximação atual das funções de valor.


2. Passo *backward*

- ▶ Resolve subproblemas “de trás para frente” para obter os multiplicadores de Lagrange das restrições associadas aos estados.
- ▶ A partir deles, constrói **cortes lineares** que aproximam melhor a função de valor, usando como “âncora” os pontos gerados no passo *forward*.

Observações:

1. Esses dois passos se repetem até que as aproximações se estabilizem, ou que algum critério de parada seja satisfeito.
2. Os cortes obtidos permitem que a política seja definida mesmo para cenários que não fizeram parte dos cenários originais do problema.

SDDP: cortes



Aproximação da função valor em um estágio.³

³Taken from a presentation by Andy Philpott

Uma visão modular

- ▶ A formulação base é o grafo de política linear, com os nós em série
- ▶ Podemos adicionar muitos elementos a esta formulação base, estendendo a construção para
 1. Grafos de política não-lineares
 2. Horizonte final incerto
 3. Horizonte infinito
 4. Bi-objetivo
 5. Dependência temporal (processo auto-regressivos)
 6. Modelos do tipo decisão-incerteza (ao invés de incerteza decisão)
 7. Incerteza dependente da decisão
 8. Aprendizado e Processo de Decisão de Markov Parcialmente Observável (POMDP)
 9. Aversão à risco
 10. Variáveis inteiras

Horizonte infinito CACS

- ▶ Temos um fator de desconto $\alpha \in [0, 1)$ que pondera o presente em relação ao futuro.
- ▶ Uma grande vantagem de trabalhar com horizonte infinito é que não precisamos especificar uma função valor terminal.
- ▶ Em cada estágio, resolvemos o problema com probabilidade α , ou o encerramos com probabilidade $1 - \alpha$ (“desenrolando” o grafo de políticas até um máximo de τ nós).
- ▶ Se $C_i(x_i, u_i^*, \omega_i) \leq M < \infty$, então temos:

$$-\frac{M}{1-\alpha} \leq \mathbb{E}_{j \in R^+; \omega_j \in \Omega_j} [V(x_i, \omega_j)] \leq \frac{M}{1-\alpha},$$

o que implica que

$$\left| \mathbb{E}_{i \in R^+; \omega_i \in \Omega_i} [V(x_R, \omega_i)] - \mathbb{E}_{i \in R^+; \omega_i \in \Omega_i} [\bar{V}^*(x_R, \omega_i)] \right| = \varepsilon \leq \alpha^\tau \times \frac{2M}{1-\alpha}.$$

Exemplo 1: Problema de despacho hidrotérmico

- ▶ O agente controla um gerador hidrelétrico, um reservatório e uma unidade térmica.
- ▶ As decisões de cada estágio, g_t e g_h , devem ser tomadas para atender a uma demanda aleatória w_d .
- ▶ O volume do reservatório deve permanecer entre 5 e 15 unidades, e o estado inicial é $x_0 = 10$.
- ▶ Consideram-se três estágios: verão-outono, inverno e primavera, e o problema é resolvido em um *horizonte infinito*, com fator de desconto $\alpha = 0.95$.
- ▶ As afluências também são aleatórias, e o par (afluência, demanda) é sorteado de $(w_i, w_d) \in \{(0, 7.5), (3, 5), (10, 2.5)\}$, com probabilidades iguais.
- ▶ A água vertida do reservatório, s , é penalizada na função objetivo, e os custos térmicos são dados por $t \times g_t$ em cada estágio.

Exemplo 2: um problema de estoque

Considere um problema de revisão periódica de estoques envolvendo um único produto, com $x_0 \geq 0$. Um agente pode fazer pedidos no início de cada estágio, e o objetivo é minimizar o custo esperado ao longo do horizonte de planejamento.

- ▶ $c = 35$ é o custo unitário de aquisição,
- ▶ $h = 1$ é o custo de manutenção em estoque,
- ▶ $p = 15$ é o custo de falta,
- ▶ Não há custos fixos de pedido, a demanda segue $D \sim U(0, 800)$, e a demanda não atendida é retroativa (backlog).
- ▶ Em cada estágio, o agente deve decidir qual será o nível de estoque no início do próximo estágio.


$$V_t(x) = \min_{y \geq x} \left\{ c(y - x) + L(y) + \alpha \int_0^\infty V_{t+1}(y - \xi) \phi(\xi) d\xi \right\},$$

onde


$$L(y) = \int_0^y h(y - \xi) \phi(\xi) d\xi + \int_y^\infty p(\xi - y) \phi(\xi) d\xi.$$

1. **Formulação de horizonte finito:** considere T estágios, com função valor terminal $v_T(x) = cx$.
2. **Formulação de horizonte infinito:** assuma um fator de desconto $\alpha = 0,90$.

Horizonte finito



Horizonte infinito



Dependência da decisão dentro do PG I

- ▶ Em um MDP, normalmente temos probabilidades de transição $\mathbb{P}(x' \mid x, u)$.
- ▶ Aqui, o próximo estado (x', i') depende de duas partes: $x' = T_i(u, x, \omega_i)$ e $\phi_{i,i'}$. A primeira (transição determinística) depende da ação do agente, enquanto a segunda (transição probabilística) não depende.
- ▶ Incorporamos a dependência da decisão da seguinte forma:

$$\min_{\pi \in \Pi} \sum_{i \in R^+} \phi_{R,i} \sum_{\omega \in \Omega_i} \mathbb{P}_i(\omega) \cdot V_i(x_R, \omega),$$

onde:

$$\begin{aligned} V_i(x, \omega_i) = \min_{u, x', y} \quad & C_i(u, x', \omega_i) + C'_i(y) + \sum_{j \in i^+; \omega \in \Omega_j} \phi_{ij}(y) \cdot \mathbb{P}_j(\omega) \cdot V_j(x', \omega) \\ \text{s.a.} \quad & (u, x') \in \mathcal{X}_i(x, \omega_i), \\ & y \in \mathcal{Y}. \end{aligned}$$

Matriz de transição dependente da decisão


$$\phi_{ij}(y) = \phi_{ij}^0(1 + a_j^\top y), \quad \text{para } i, j \in \mathcal{N}.$$

Dependência da decisão dentro do PG II


$$\begin{aligned} V_i(x, \omega_i) = \min_{u, x', y} \quad & C_i(u, x', y, \omega_i) + \sum_{d \in D} y_d \sum_{j \in i^+; \omega \in \Omega_j} \phi_{ij}^d \cdot \mathbb{P}_j(\omega) \cdot V_j(x', \omega) \\ \text{s.a.} \quad & (u, x', y) \in \mathcal{X}_i(x, \omega_i), \\ & \sum_{d \in D} y_d = 1, \\ & y_d \in \{0, 1\}, \quad d \in D. \end{aligned}$$

- ▶ Assume-se um conjunto limitado de possíveis matrizes de transição $\{\Phi^d\}_{d \in D}$
- ▶ Em cada nó, $y_d \in \{0, 1\}$ especifica qual matriz será usada no próximo estágio
- ▶ Permite-se acoplamento entre u e y , e uma forma mais geral de função de custo $C_i(u, x', y, \omega_i)$
- ▶ Ambas as formulações são desafiadoras, pois os produtos entre y (ou y_d) e $V_j(x', \omega_j)$ induzem não convexidades
- ▶ Se a função de custo futuro é convexa para y fixo, então a otimização sobre y resulta no mínimo de um conjunto de funções convexas — isto é, uma função de custo futuro **não convexa, mas convexa por partes**.

O produtor de queijo




Solução



Uma trajetória de simulação da política do produtor de queijo ao longo de 50 períodos de tempo. As cruzes vermelhas correspondem aos estados em que $y = 0$ e o agricultor **não** vai ao mercado, enquanto os círculos verdes correspondem aos estados em que $y = 1$ e o agricultor vai ao mercado.

O produtor de queijos marketeiro



Outline

Introdução

O mundo dos Processos de Decisão de Markov (MDPs)

CACS: Uma introdução aos grafos de políticas (PG)

Exemplos práticos

Dependência na decisão

Risco

Conclusões

Medidas de risco

- ▶ A abordagem tradicional em Programação Estocástica é usar o **valor esperado** para lidar com a incerteza.
- ▶ Em problemas clássicos de dois ou múltiplos estágios, normalmente busca-se minimizar os **custos esperados**.
- ▶ Mas e se quisermos estar protegidos contra **casos extremos**?
- ▶ As **medidas de risco** são uma forma de incorporar aversão ao risco no problema.
- ▶ Existem outras abordagens — economistas, por exemplo, usam **funções utilidade**.

Medidas de risco coerentes

Uma *medida de risco* é uma função $\mathbb{F}$ que mapeia uma variável aleatória $Z \in \mathcal{Z}$ em $\mathbb{R}$. Diz-se que uma medida de risco é *coerente* se, para $Z_1, Z_2 \in \mathcal{Z}$, ela satisfaz os seguintes axiomas (Artzner et al., '99):

1. **Monotonicidade:** Se $Z_1 \leq Z_2$, quase certamente, então $\mathbb{F}[Z_1] \leq \mathbb{F}[Z_2]$.
2. **Equivariança por translação:** $\mathbb{F}[Z + a] = \mathbb{F}[Z] + a$, para todo $a \in \mathbb{R}$.
3. **Subaditividade:** $\mathbb{F}[Z_1 + Z_2] \leq \mathbb{F}[Z_1] + \mathbb{F}[Z_2]$.
4. **Homogeneidade positiva:** $\mathbb{F}[aZ] = a\mathbb{F}[Z]$, para todo $a \geq 0$.

Exemplos

Valor em Risco Condicional (CVaR):

$$\text{CV@R}_\gamma[Z] = \inf_{\zeta \in \mathbb{R}} \left\{ \zeta + \frac{1}{1-\gamma} \mathbb{E}[(Z - \zeta)_+] \right\},$$

Quando $\gamma = 0$, temos $\text{CV@R}_0[Z] = \mathbb{E}[Z]$, e quando $\gamma \rightarrow 1$, $\text{CV@R}_\gamma[Z] \rightarrow \text{ess sup}[Z]$.

Semidesvio superior médio de ordem p :

$$\mathbb{F}[Z] := \mathbb{E}[Z] + c \left(\mathbb{E} \left[[Z - \mathbb{E}[Z]]_+^p \right] \right)^{1/p}, \quad c \in [0, 1], p \in [1, \infty).$$


Medidas de risco convexas

1. **Convexidade:** $\mathbb{F}[aZ_1 + (1 - a)Z_2] \leq a\mathbb{F}[Z_1] + (1 - a)\mathbb{F}[Z_2]$ para todo $a \in [0, 1]$.
2. **Monotonicidade:** Se $Z_1 \leq Z_2$, quase certamente, então $\mathbb{F}[Z_1] \leq \mathbb{F}[Z_2]$.
3. **Equivariança por translação:** $\mathbb{F}[Z + a] = \mathbb{F}[Z] + a$, para todo $a \in \mathbb{R}$.

Uma medida de risco convexa que não é coerente: a medida de risco entrópica

$$\text{ENT}_\gamma[Z] = \frac{1}{\gamma} \log \left(\mathbb{E}[e^{\gamma Z}] \right),$$

onde $\gamma > 0$. Temos que $\lim_{\gamma \rightarrow 0} \text{ENT}_\gamma[Z] = \mathbb{E}[Z]$ e $\lim_{\gamma \rightarrow \infty} \text{ENT}_\gamma[Z] = \text{ess sup}[Z]$.



Convex

$\mathbb{E}[X]$

$\text{ess sup}[Z]$

Coherent

Consistência condicional

$$\text{Risco no fim do horizonte}(Z) = \mathbb{F}[Z_1 + Z_2 + \cdots + Z_T].$$

$$\text{Risco aninhado}(Z) = \mathbb{F}[Z_1 + \mathbb{F}[Z_2 + \mathbb{F}[\cdots + \mathbb{F}[Z_T] \cdots] \mid Z_2] \mid Z_1].$$

Consistência condicional

Sejam (X_1, X_2) e (Y_1, Y_2) dois vetores de dimensão 2 para os quais as expectativas necessárias são finitas. Uma medida de risco $\mathbb{F}$ é dita *condicionalmente consistente* se:

$$\mathbb{F}[X_1 + X_2] \leq \mathbb{F}[Y_1 + Y_2] \iff \mathbb{F}[X_1 + \mathbb{F}[X_2 \mid X_1]] \leq \mathbb{F}[Y_1 + \mathbb{F}[Y_2 \mid Y_1]].$$

Formulação multistágio

Consideremos um programa estocástico multistágio com T estágios, cujo problema nas variáveis do primeiro estágio é dado por:

$$\begin{aligned} V_1 = \min_{x_1} \quad & c_1^\top x_1 + \mathbb{E}_{\omega_2 \in \Omega_2} [V_2(x_1, \omega_2)] \\ & A_1 x_1 = b_1 \\ & x_1 \geq 0, \end{aligned}$$

onde o problema do segundo estágio é substituído por um problema genérico no estágio t , para $t = 2, \dots, T$:

$$\begin{aligned} V_t(x_{t-1}, \omega_t) = \min_{\bar{x}_t, x_t} \quad & c_t^\top x_t + \mathbb{E}_{\omega_{t+1} \in \Omega_{t+1}} [V_{t+1}(x_t, \omega_{t+1})] \\ & \bar{x}_t = x_{t-1} \quad [\lambda] \\ & A_t x_t + B_t \bar{x}_t = b_t \\ & x_t \geq 0. \end{aligned}$$

Aproximação convexa


$$\begin{aligned} V_1^K &= \min_{x_1, \theta_2} && c_1^\top x_1 + \theta_2 \\ &&& A_1 x_1 = b_1 \\ &&& x_1 \geq 0 \\ &&& \theta_2 \geq \alpha_{2,k} + \beta_{2,k}^\top x_1, \quad k = 1, \dots, K-1 \\ &&& \theta_2 \geq -M_2, \end{aligned}$$

$$\begin{aligned} V_t^K(x_{t-1}, \omega_t) &= \min_{\bar{x}_t, x_t, \theta_{t+1}} && c_t^\top x_t + \theta_{t+1} \\ &&& \bar{x}_t = x_{t-1} \quad [\lambda] \\ &&& A_t x_t + B_t \bar{x}_t = b_t \\ &&& x_t \geq 0 \\ &&& \theta_{t+1} \geq \alpha_{t+1,k} + \beta_{t+1,k}^\top x_t, \quad k = 1, \dots, K-1 \\ &&& \theta_{t+1} \geq -M_{t+1}, \end{aligned}$$

onde M_{t+1} é um limite inferior para $\mathbb{E}[V_{t+1}(\cdot, \omega_{t+1})]$.

Exemplo: redes rodoviárias

- Diversas medidas de risco, incluindo a CVaR e a Entrópica, estão implementadas em `SDDP.jl`.
- Resolvemos um pequeno problema de rede rodoviária (Torricco & Comminetti, 2016) para ilustrar as vantagens da medida entrópica sobre a CVaR, usando a propriedade $\mathbb{F}[X + Z] \leq \mathbb{F}[Y + Z] \iff \mathbb{F}[X] \leq \mathbb{F}[Y]$.



$\mathbb{P}(\omega)$	Ω_X	Ω_Y	Ω_Z
0.9	1.8	1.7	1.0
0.1	2.0	2.2	2.0

Implementação

Notação: $\Omega_{X,Y,Z} = \Omega_X \times \Omega_Y \times \Omega_Z$.

Formulação no fim do horizonte

$$V_1 = \min_{x \in \{0,1\}} \mathbb{F}_{\omega \in \Omega_{X,Y,Z}} [V_2(x, \omega_x, \omega_y, \omega_z)],$$

onde $V_2(x, \omega_x, \omega_y, \omega_z) = X(\omega_x)x + Y(\omega_y)(1-x) + Z(\omega_z)$. Esta formulação é equivalente a escolher entre $\mathbb{F}[X + Z]$ e $\mathbb{F}[Y + Z]$.

Formulação aninhada

$$V_1 = \min_{x \in \{0,1\}} \mathbb{F}_{\omega \in \Omega_{X,Y}} [V_2(x, \omega_x, \omega_y)],$$

onde:

$$V_2(x, \omega_x, \omega_y) = X(\omega_x)x + Y(\omega_y)(1-x) + \mathbb{F}_{\omega \in \Omega_Z} [V_3(x, \omega_z)],$$

e $V_3(x, \omega_z) = Z(\omega_z)$. Esta formulação é equivalente a escolher entre $\mathbb{F}[X + \mathbb{F}_{Z|X}[Z]]$ e $\mathbb{F}[Y + \mathbb{F}_{Z|Y}[Z]]$.




Gráfico da decisão ótima do primeiro estágio x versus o parâmetro de aversão à risco γ usando o CVaR (gráfico a) e a Entrópica (gráfico b). $x = 0$ significa que escolhemos a o caminho Y , e $x = 1$ significa que escolhemos o caminho X .

Resumo: risco

- ▶ Discutimos medidas de risco como uma alternativa ao valor esperado em problemas de decisão sob incerteza
- ▶ Abordamos medidas de risco coerentes e não coerentes
- ▶ Apresentamos a medida entrópica como uma opção muito desejável para o contexto multistágio: apesar de não ser coerente, ela é condicionalmente consistente
- ▶ É tratável, e problemas multistágio avessos ao risco (MSSP) podem ser resolvidos de forma eficiente usando SDDP

Outline

Introdução

O mundo dos Processos de Decisão de Markov (MDPs)

CACS: Uma introdução aos grafos de políticas (PG)

Exemplos práticos

Dependência na decisão

Risco

Conclusões

Conclusões

- ▶ Apresentei uma estrutura bastante ampla para lidar com problemas de tomada de decisão sequencial.
- ▶ A abordagem não depende de árvores de cenários e está muito mais próxima do mundo dos MDPs.
- ▶ Um elemento-chave é que podemos tratar diretamente problemas do tipo CACS.
- ▶ A abordagem tem uma visão modular: pode lidar com problemas de horizonte infinito, dependência da decisão (DDU), aprendizado, aversão ao risco, objetivos múltiplos, processos dependentes do estágio, entre outros.
- ▶ É uma área ativa de pesquisa: integralidade, novos domínios de aplicação, combinações inteligentes dos módulos existentes, novas estratégias algorítmicas para lidar com não convexidades e extensões para problemas multiagente.

Obrigado!

Bernardo K. Pagnoncelli

`bernardo.pagnoncelli@skema.edu`