

Geração de Cenários por Amostragem

Tito Homem-de-Mello


Escola de Negócios
Universidade Adolfo Ibañez, Santiago, Chile

SOBRAPO School
Curso de Otimização Estocástica
Aula 4
28 de novembro, 2025

Minha história

- Graduação: Ciência da Computação (IME-USP)
- Mestrado: Matemática Aplicada (IME-USP)
- Doutorado: Engenharia Industrial e de Sistemas, Georgia Tech (EUA)
- Professor na Ohio State University e Northwestern University (EUA)
- Atualmente (desde 2011):

Estou aqui



Problemas lineares com incerteza

Muitos problemas de otimização podem ser formulados através de funções lineares:

$$\begin{aligned} \min \quad & b^T x \\ \text{s.t.} \quad & Ax \geq c. \end{aligned} \tag{LP}$$

Suponha que haja alguma incerteza nos coeficientes A e c .

Por exemplo, a restrição $Ax \geq c$ poderia representar “a produção total de energia deve satisfazer a demanda”, mas

- A demanda é incerta.
- A quantidade real produzida a partir de cada fonte de energia é uma porcentagem (aleatória) da quantidade planejada.

O que fazer?

Lidando com a incerteza

Algumas possibilidades:

- Impor que a restrição $Ax \geq c$ deve ser satisfeita independentemente do resultado de A e c .
- Impor que a restrição $Ax \geq c$ deve ser satisfeita com alguma probabilidade, ou seja, resolver

$$\min \{b^T x : P(Ax \geq c) \geq 1 - \alpha\} \quad \text{para algum } \alpha > 0 \text{ pequeno.}$$

- Penalizar a *violação esperada da restrição*, ou seja, resolver

$$\min b^T x + \mu \mathbb{E}[\max\{c - Ax, 0\}] \quad \text{para algum } \mu > 0.$$

Dificuldade: Como resolver qualquer uma destas formulações?

A necessidade de aproximação

Antes mesmo de pensarmos em métodos de otimização para resolver os problemas acima, precisamos lidar com uma questão ainda mais básica:

- Como *calcular* quantidades como $P(Ax \geq c)$ ou $\mathbb{E}[\max\{c - Ax, 0\}]$?
- Muito difícil de fazer! (exceto em casos especiais)
- Precisamos **aproximar** essas quantidades com algo que possamos calcular.


O problema da estimativa: um exemplo

Suponha que temos um vetor de m variáveis aleatórias $X := (X_1, \dots, X_m)$ e queremos calcular

$$g := \mathbb{E}[G(X)] = \mathbb{E}[G(X_1, \dots, X_m)],$$

onde G é uma função que mapeia vetores de dimensão m para os números reais.

Exemplo: encontrar o **tempo de conclusão** esperado de um projeto.



O projeto tem 3 componentes,
dados pelas atividades

1

2 e 5

3, 4 e 5

$$G(X) = \max\{X_1, X_2 + X_5, X_3 + X_4 + X_5\}$$

O problema da estimativa

Como fazer isso?

- Suponha que cada variável X_k possa assumir r valores possíveis, denotados por $x_k^1, \dots, x_k^r$. Se quisermos calcular o valor **exato**, temos que calcular


$$\mathbb{E}[G(X)] = \sum_{k_1=1}^r \sum_{k_2=1}^r \dots \sum_{k_m=1}^r G(x_1^{k_1}, \dots, x_m^{k_m}) P(X_1 = x_1^{k_1}, \dots, X_m = x_m^{k_m})$$

- No exemplo acima, suponha que cada variável possa assumir $r = 10$ valores. Se as durações das atividades forem independentes, então temos um total de

$$10^5 = 100.000 \text{ resultados possíveis para } G(X)!$$

O problema da estimativa

Imagine agora este projeto:



É totalmente impraticável calcular o valor exato!

- O problema é ainda pior se as distribuições forem *contínuas*.

A necessidade de cenários

O exemplo mostra que precisamos de um método que nos ajude a aproximar distribuições com um conjunto finito (e não muito grande) de **cenários**.

Questões:

- Como selecionar tal conjunto de cenários?
- Que garantias podem ser dadas sobre a qualidade da aproximação?

Como veremos, existem duas classes de abordagens:

- Métodos de *amostragem*
- Métodos *determinísticos*

Cada classe requer suas próprias ferramentas para responder às duas perguntas acima.

O problema da estimativa por amostragem (método Monte Carlo)

Ideia: Seja $X^j := (X_1^j, \dots, X_m^j)$ uma **amostra** do vetor aleatório X .

- Extraia N amostras *independentes e identicamente distribuídas* (iid) $X^1, \dots, X^N$.
- Calcule

$$\hat{g}_N := \frac{1}{N} \sum_{j=1}^N G(X^j).$$

Recordemos a *Lei Forte dos Grandes Números*: à medida que N tende para o infinito,


$$\lim_{N \rightarrow \infty} \hat{g}_N = \mathbb{E}[G(X)] \text{ com probabilidade 1 (c.p.1).}$$

Portanto, podemos usar $\hat{g}_N$ como uma aproximação de $g = \mathbb{E}[G(X)]$.

Avaliação da qualidade da aproximação

PROBLEMA: $\hat{g}_N$ é uma variável aleatória, uma vez que depende da amostra.


- Ou seja, em uma experiência, $\hat{g}_N$ pode estar próximo de g , enquanto em outra pode diferir de g em uma grande quantidade!
- Exemplo: 200 execuções do problema do tempo de conclusão com $N = 50$.



Avaliação da qualidade da aproximação

PROBLEMA: $\hat{g}_N$ é uma variável aleatória, uma vez que depende da amostra.

- Ou seja, num experimento $\hat{g}_N$ pode estar próximo de g , enquanto em outro pode diferir de g em uma grande quantidade!
- Exemplo: 200 execuções do problema do tempo de conclusão de projeto com $N = 50$.



O Teorema do Limite Central

Observe que

$$\mathbb{E}[\hat{g}_N] = \mathbb{E}\left[\frac{1}{N} \sum_{j=1}^N G(X^j)\right] = \frac{1}{N} \sum_{j=1}^N \mathbb{E}[G(X^j)] = g.$$

Além disso,

$$\text{Var}(\hat{g}_N) = \text{Var}\left(\frac{1}{N} \sum_{j=1}^N G(X^j)\right) = \frac{1}{N^2} \sum_{j=1}^N \text{Var}(G(X^j)) = \frac{1}{N} \text{Var}(G(X)).$$

O **Teorema do Limite Central** afirma que, para N suficientemente grande,

$$\frac{\sqrt{N}(\hat{g}_N - g)}{\sigma} \approx \text{Normal}(0; 1),$$

onde $\sigma^2 = \text{Var}(G(X))$.

Cálculo da margem de erro da estimativa

O TLC implica que

$$P\left(\hat{g}_N - z_{1-\alpha/2} \frac{\sigma}{\sqrt{N}} \leq g \leq \hat{g}_N + z_{1-\alpha/2} \frac{\sigma}{\sqrt{N}}\right) \approx 1 - \alpha,$$

onde $z_{1-\alpha/2}$ denota o percentil $1 - \alpha/2$ da distribuição Normal(0,1) (por exemplo, $z_{1-\alpha/2} = 1,96$ para $\alpha = 0,05$).

Ou seja, se fizermos 100 experimentos, em 95 deles (em média) o intervalo dado por

$$\left[\hat{g}_N - 1,96 \frac{\sigma}{\sqrt{N}}, \hat{g}_N + 1,96 \frac{\sigma}{\sqrt{N}}\right]$$

conterá o valor verdadeiro g .

O intervalo acima é chamado de **intervalo de confiança de 95%** para g .

- Quando N é grande o suficiente, podemos aproximar σ^2 com

$$S_N^2 := \frac{\sum_{j=1}^N (G(X^j) - \hat{g}_N)^2}{N - 1}.$$

Da estimativa à otimização

Considere um problema genérico de otimização estocástica da forma

$$\min_{x \in X} \{g(x) := \mathbb{E}[G(x, \xi)]\}, \quad (\text{SP})$$

onde:

- G é uma função de valor real que representa a quantidade de interesse (custo, gastos, emissões de CO_2 , etc.).
- Os parâmetros de G são o vetor de decisão x e um vetor aleatório ξ que representa a incerteza no problema.
- X é o conjunto de pontos viáveis.

A necessidade de aproximação

Lição (#1)

*Salvo em casos específicos onde G é uma função simples, ou quando o número de cenários é relativamente pequeno, sempre vamos precisar **aproximar o problema**, uma vez que não podemos avaliar $g(x)$ com exatidão.*

- Como antes, podemos usar amostragem ou aproximações determinísticas.
- **Questão:** Qual é o efeito da aproximação no valor ótimo e/ou nas soluções ótimas do problema?

O problema do jornaleiro, revisitado

O jornaleiro compra jornais pela manhã ao preço c e os vende durante o dia ao preço r .

Os jornais não vendidos são devolvidos no final do dia pelo valor residual s .

Se quisermos maximizar a receita *esperada*, temos que resolver

$$\max_{x \geq 0} \{ \mathbb{E}[-G(x, \xi)] \},$$

ou equivalentemente

$$\min_{x \geq 0} \{ g(x) := \mathbb{E}[G(x, \xi)] \},$$

onde

$$\begin{aligned} G(x, \xi) &:= cx - r \min\{x, \xi\} - s(x - \min\{x, \xi\}) \\ &= (c - s)x + (s - r) \min\{x, \xi\}. \end{aligned}$$


Aproximação com amostragem

Como vimos anteriormente, podemos aproximar o valor de $g(x)$ (para cada x dado) com uma média amostral.

Ou seja, para cada $x \in X$, podemos extrair uma amostra $\{\xi_x^1, \dots, \xi_x^N\}$ da distribuição de ξ e aproximar $g(x)$ com

$$\tilde{g}_N(x) := \frac{1}{N} \sum_{j=1}^N G(x, \xi_x^j).$$

Mas: É inútil gerar uma nova aproximação para cada x !




A abordagem da aproximação da média amostral

A ideia da abordagem da **aproximação por média amostral** (Sample Average Approximation, SAA) é usar a **mesma** amostra para **todos** os x .

Ou seja, extraímos uma amostra $\{\xi^1, \dots, \xi^N\}$ da distribuição de ξ e aproximamos $g(x)$ com

$$\hat{g}_N(x) := \frac{1}{N} \sum_{j=1}^N G(x, \xi^j).$$



A abordagem SAA

Podemos ver que a aproximação é muito próxima da função real.

Isso sugere substituir o problema original por

$$\min_{x \in X} \hat{g}_N(x),$$

que pode ser resolvido usando um algoritmo de otimização determinístico!

Perguntas:

- Isso sempre funciona, ou seja, para qualquer função $G(x, \xi)$?
- Qual é o tamanho “adequado” da amostra a ser utilizada?
- O que pode ser dito sobre a qualidade da solução retornada pelo algoritmo?

Propriedades assintóticas

Vamos estudar primeiro o que acontece quando o tamanho da amostra N tende a infinito.

É importante entender o que isso significa. Considere o seguinte experimento *hipotético*:

- Extraímos uma amostra de tamanho infinito, chamada $\{\xi^1, \xi^2, \dots\}$. Chamamos isso de **trajetória amostral**.
- Então, para cada N , construímos a aproximação

$$\hat{g}_N(\cdot) = \frac{1}{N} \sum_{j=1}^N G(\cdot, \xi^j)$$

usando **os primeiros N termos dessa trajetória amostral**, e resolvemos

$$\min_{x \in X} \hat{g}_N(x). \quad (\text{SP}_N)$$

Propriedades assintóticas

Sejam

$\hat{x}_N :=$ uma solução ótima de (SP_N)

$S_N :=$ o conjunto de soluções ótimas de (SP_N)

$\nu_N :=$ o valor ótimo de (SP_N)

e

$x^* :=$ uma solução ótima de (SP)

$S^* :=$ o conjunto de soluções ótimas de (SP)

$\nu^* :=$ o valor ótimo de (SP)

À medida que o tamanho da amostra N tende a infinito,


- $\hat{x}_N$ converge para algum x^* ?
- S_N converge para o conjunto S^* ?
- ν_N converge para ν^* ?

Propriedades assintóticas, distribuições contínuas

Ilustramos as propriedades assintóticas com o problema do vendedor de jornais.

Estudaremos separadamente os casos em que a demanda ξ tem uma distribuição **contínua** e uma distribuição **discreta**.

Suponha inicialmente que a demanda tenha uma distribuição exponencial com média 10.



Propriedades assintóticas, distribuições contínuas

Parece que as funções $\hat{g}_N$ estão convergindo para g . A tabela lista os valores de $\hat{x}_N$ e ν_N ($N = \infty$ corresponde à função verdadeira):


N	10	30	90	270	∞
$\hat{x}_N$	1,46	1,44	1,54	2,02	2,23
ν_N	-1,11	-0,84	-0,98	-1,06	-1,07

Portanto, vemos que $\hat{x}_N \rightarrow x^*$ e $\nu_N \rightarrow \nu^*$!

Propriedades assintóticas, distribuições discretas

Agora, vamos analisar o caso em que ξ tem uma distribuição **discreta**.

Suponha que a demanda tenha distribuição uniforme discreta em $\{1, 2, \dots, 10\}$.



Propriedades assintóticas, distribuições discretas

Outra vez, parece que as funções $\hat{g}_N$ estão convergindo para g . A tabela lista os valores de $\hat{x}_N$ e ν_N ($N = \infty$ corresponde à função verdadeira):

N	10	30	90	270	∞
$\hat{x}_N$	2	3	3	2	[2,3]
ν_N	-2,00	-2,50	-1,67	-1,35	-1,50

Vemos que $\nu_N \rightarrow \nu^*$. No entanto, $\hat{x}_N$ não parece estar convergindo de forma alguma.

- Por outro lado, $\hat{x}_N$ está oscilando entre duas soluções ótimas do problema real!

Quão geral é essa conclusão?

Resultado da convergência

Podemos ver em ambas as figuras que $\hat{g}_N(\cdot)$ converge *uniformemente* para $g(\cdot)$.

- A convergência uniforme ocorre, por exemplo, quando as funções são *convexas*.

O resultado a seguir é geral:

Lição (#2)

Quando a convergência é uniforme, temos os seguintes resultados:


- 1 $\nu_N \rightarrow \nu^*$ com probabilidade 1 (c.p.1),
- 2 Sob hipóteses técnicas adequadas, $\text{dist}(S_N, S^*) \rightarrow 0$ w.p.1, ou seja, no limite temos $S_N \subseteq S^*$.

Resultado da convergência (cont.)


O que significa “convergência com probabilidade 1”?

- Recordemos que as funções $\hat{g}_N$ no exemplo acima foram construídas a partir de uma *única* trajetória amostral $\{\xi^1, \xi^2, \dots\}$.
- O teorema nos diz que, independentemente da trajetória amostral que escolhermos, temos convergência quando $N \rightarrow \infty$!

Então, vamos repetir o experimento acima (apenas para $N = 270$) várias vezes, cada vez com uma trajetória amostral diferente:



(a) Demanda exponencial



(b) Demanda
uniforme discreta

Resultado da convergência (cont.)

Vemos que, para algumas trajetórias amostrais, temos uma aproximação muito boa para este N (neste caso, $N = 270$), mas para outras não.

Por quê? Não temos convergência para todas as trajetórias amostrais?

- O problema é que o teorema só garante a convergência quando $N \rightarrow \infty$.
- Assim, para algumas trajetórias amostrais, obtemos rapidamente uma boa aproximação, enquanto que para outras podemos precisar de um N maior para alcançar a mesma qualidade.

Em qual trajetória estamos?

- Dado o anterior, se escolhermos *uma amostra de tamanho N* e resolvermos $\min \hat{g}_N(x)$ conforme indicado pela abordagem SAA, como saberemos se estamos numa trajetória amostral “boa” ou “ruim”?
- A resposta é... não sabemos!


Lição (#3)

*Não podemos apenas escolher uma amostra de tamanho N e resolver o problema SAA. Podemos ter azar e nossa mostra resultar numa má solução! Precisamos ter algumas **garantias probabilísticas**.*

Avaliando a qualidade de uma solução

O problema de garantias de otimalidade está diretamente relacionado à seguinte pergunta:

- Dada uma solução viável $\hat{x}$, como determinamos se é uma boa solução?
- Não sabemos o quão longe $\hat{x}$ está de uma solução ótima! O único que sabemos é que $\nu^* \leq g(\hat{x})$.
- **Mas:** Se conhecemos um *limite inferior* $\underline{\nu}$ para ν^* (ou seja, $\underline{\nu} \leq \nu^*$), e se $g(\hat{x}) - \nu^*$ é relativamente pequeno, então $\hat{x}$ é uma boa solução!



Como encontramos um limite inferior?

Vimos anteriormente que o valor ótimo do problema SAA (ν_N) converge ao valor ótimo real ν^* .

- Por outro lado, ν_N é um estimador **enviesado** de ν^* , ou seja,

$$\mathbb{E}[\nu_N] \leq \nu^*.$$

- Por quê? Basta observar, por exemplo para $N = 2$, que

$$\begin{aligned}\nu_2 &= \min_x \frac{1}{2} (G(x, \xi^1) + G(x, \xi^2)) \leq \frac{1}{2} (G(x, \xi^1) + G(x, \xi^2)) \quad \forall x \\ \implies \mathbb{E}[\nu_2] &\leq \frac{1}{2} \mathbb{E} [G(x, \xi^1) + G(x, \xi^2)] = \mathbb{E} [G(x, \xi)] = g(x) \quad \forall x \\ \implies \mathbb{E}[\nu_2] &\leq \min_x g(x) = \nu^*.\end{aligned}$$

- O argumento para um N qualquer é muito similar.

O intervalo de otimalidade

Temos então

$$\mathbb{E}[\nu_N] \leq \nu^* \leq g(\hat{x}).$$

- O termo mais à esquerda pode ser estimado tomando-se $M + 1$ mostras de tamanho N cada uma, e *calculando o valor ótimo ν_N^k de cada problema SAA*. Tal como vimos anteriormente, o intervalo de confiança $(1 - \alpha)100\%$ para $\mathbb{E}[\nu_N]$ é dado por

$$\bar{\nu}_M \pm z_{1-\alpha/2} \frac{s_M}{\sqrt{M}},$$

onde

$$\bar{\nu}_M = \text{média de } \nu_N^1, \dots, \nu_N^M$$

$$s_M = \text{desvio padrão de } \nu_N^1, \dots, \nu_N^M$$

O intervalo de otimalidade

- O termo mais à direita pode ser estimado tomando-se 1 mostra de tamanho N , e calculando $G(\hat{x}, \xi^j)$, $j = 1, \dots, N$. O intervalo de confiança $(1 - \alpha)100\%$ para $g(\hat{x})$ é dado por

$$\hat{g}_N(\hat{x}) \pm z_{1-\alpha/2} \frac{s_N}{\sqrt{N}},$$

onde

$$\hat{g}_N(\hat{x}) = \text{média de } G(\hat{x}, \xi^1), \dots, G(\hat{x}, \xi^N)$$

$$s_N = \text{desvio padrão de } G(\hat{x}, \xi^1), \dots, G(\hat{x}, \xi^N)$$

- Uma possibilidade para escolher $\hat{x}$ é tomar a solução do problema $M + 1$ que foi calculada no passo anterior.

O intervalo de otimalidade

- Do cálculo anterior, obtemos 2 intervalos de confiança, cada um com $(1 - \alpha)100\%$.
- Mas qual é a confiança dos 2 intervalos simultaneamente?
- Para isso, precisamos da **desigualdade de Bonferroni**:

$$P(A_1 \cup \dots \cup A_N) \leq P(A_1) + \dots + P(A_N)$$

- Como usamos a desigualdade? Considere os eventos

$$A_1 := \left\{ \bar{\nu}_M \pm z_{1-\alpha/2} \frac{s_M}{\sqrt{M}} \supseteq \mathbb{E}[\nu_N] \right\}$$

$$A_2 := \left\{ \hat{g}_N(\hat{x}) \pm z_{1-\alpha/2} \frac{s_N}{\sqrt{N}} \supseteq g(\hat{x}) \right\}.$$

O intervalo de otimalidade

- Temos então

$$\begin{aligned}P(A_1 \cap A_2) &= 1 - P(A_1^c \cup A_2^c) \\&\geq 1 - (P(A_1^c) + P(A_2^c)) \\&= 1 - 2\alpha\end{aligned}$$

- Portanto, para que a probabilidade dos eventos A_1 e A_2 simultaneamente seja ao menos 95%, necessitamos que $1 - 2\alpha = 0,95$, ou seja, $\alpha = 0,025$.

O intervalo de otimalidade

- Finalmente, juntando os dois intervalos, temos que o intervalo

$$\left[\bar{\nu}_M - 2,24 \frac{s_M}{\sqrt{M}}, \hat{g}_N(\hat{x}) + 2,24 \frac{s_N}{\sqrt{N}} \right]$$

contém o valor ótimo ν^* com confiança 95%! (note que $2,24 = z_{0,9875}$).

- Caso o intervalo seja mais largo que o desejado, pode-se repetir o procedimento com um N maior.

Lição (#4)

É possível obter *garantias probabilísticas de otimalidade* para a solução do problema SAA de forma relativamente fácil, utilizando o procedimento descrito acima.

Outros métodos para geração/redução de cenários

Determinísticos:

- *Correspondência de momentos (moment matching)*: Busca encontrar distribuições com menos cenários que mantenham média, variância, etc., da distribuição original.
- *Métricas de probabilidade*: Busca encontrar distribuições com menos cenários que estejam "próximas" da distribuição original.
- *Clustering*: Agrupa cenários que sejam similares segundo critério.
- *Quasi Monte Carlo*: Extensão de regras de quadratura para aproximar integrais.

Outros métodos para geração/redução de cenários


Estatísticos:

- *Hipercubo latino*: Estratifica as amostras para reduzir variância.
- *Quasi Monte Carlo "randomizado"*: Utiliza os pontos gerados pelo método Quasi Monte Carlo, mas introduz uma perturbação aleatória a cada ponto.

Métodos dirigidos ao problema:

- Objetivo *não* é aproximar a distribuição, senão escolher os cenários que são mais adequados ao problema em questão.
- Por exemplo, se a função objetivo é uma métrica de risco tipo CVaR, vale a pena gerar mais cenários na cauda da distribuição.

Bibliografia



Surveys in Operations Research and Management Science 19 (2014) 56–85



Contents lists available at ScienceDirect

Surveys in Operations Research and Management Science

journal homepage: www.elsevier.com/locate/sorms



Review

Monte Carlo sampling-based methods for stochastic optimization



Tito Homem-de-Mello^{a,*}, Güzin Bayraksan^b

^a School of Business, Universidad Adolfo Ibáñez, Santiago, Chile

^b Integrated Systems Engineering, The Ohio State University, Columbus, OH, United States

HIGHLIGHTS

- We survey the use of Monte Carlo sampling-based methods for stochastic optimization.
- We provide over 240 references from both the optimization and simulation literature.
- We discuss the convergence of optimal solutions/values for sampling approximations.
- Topics related to the implementation of sampling-based algorithms are discussed.
- An overview of alternative sampling techniques to reduce variance is presented.